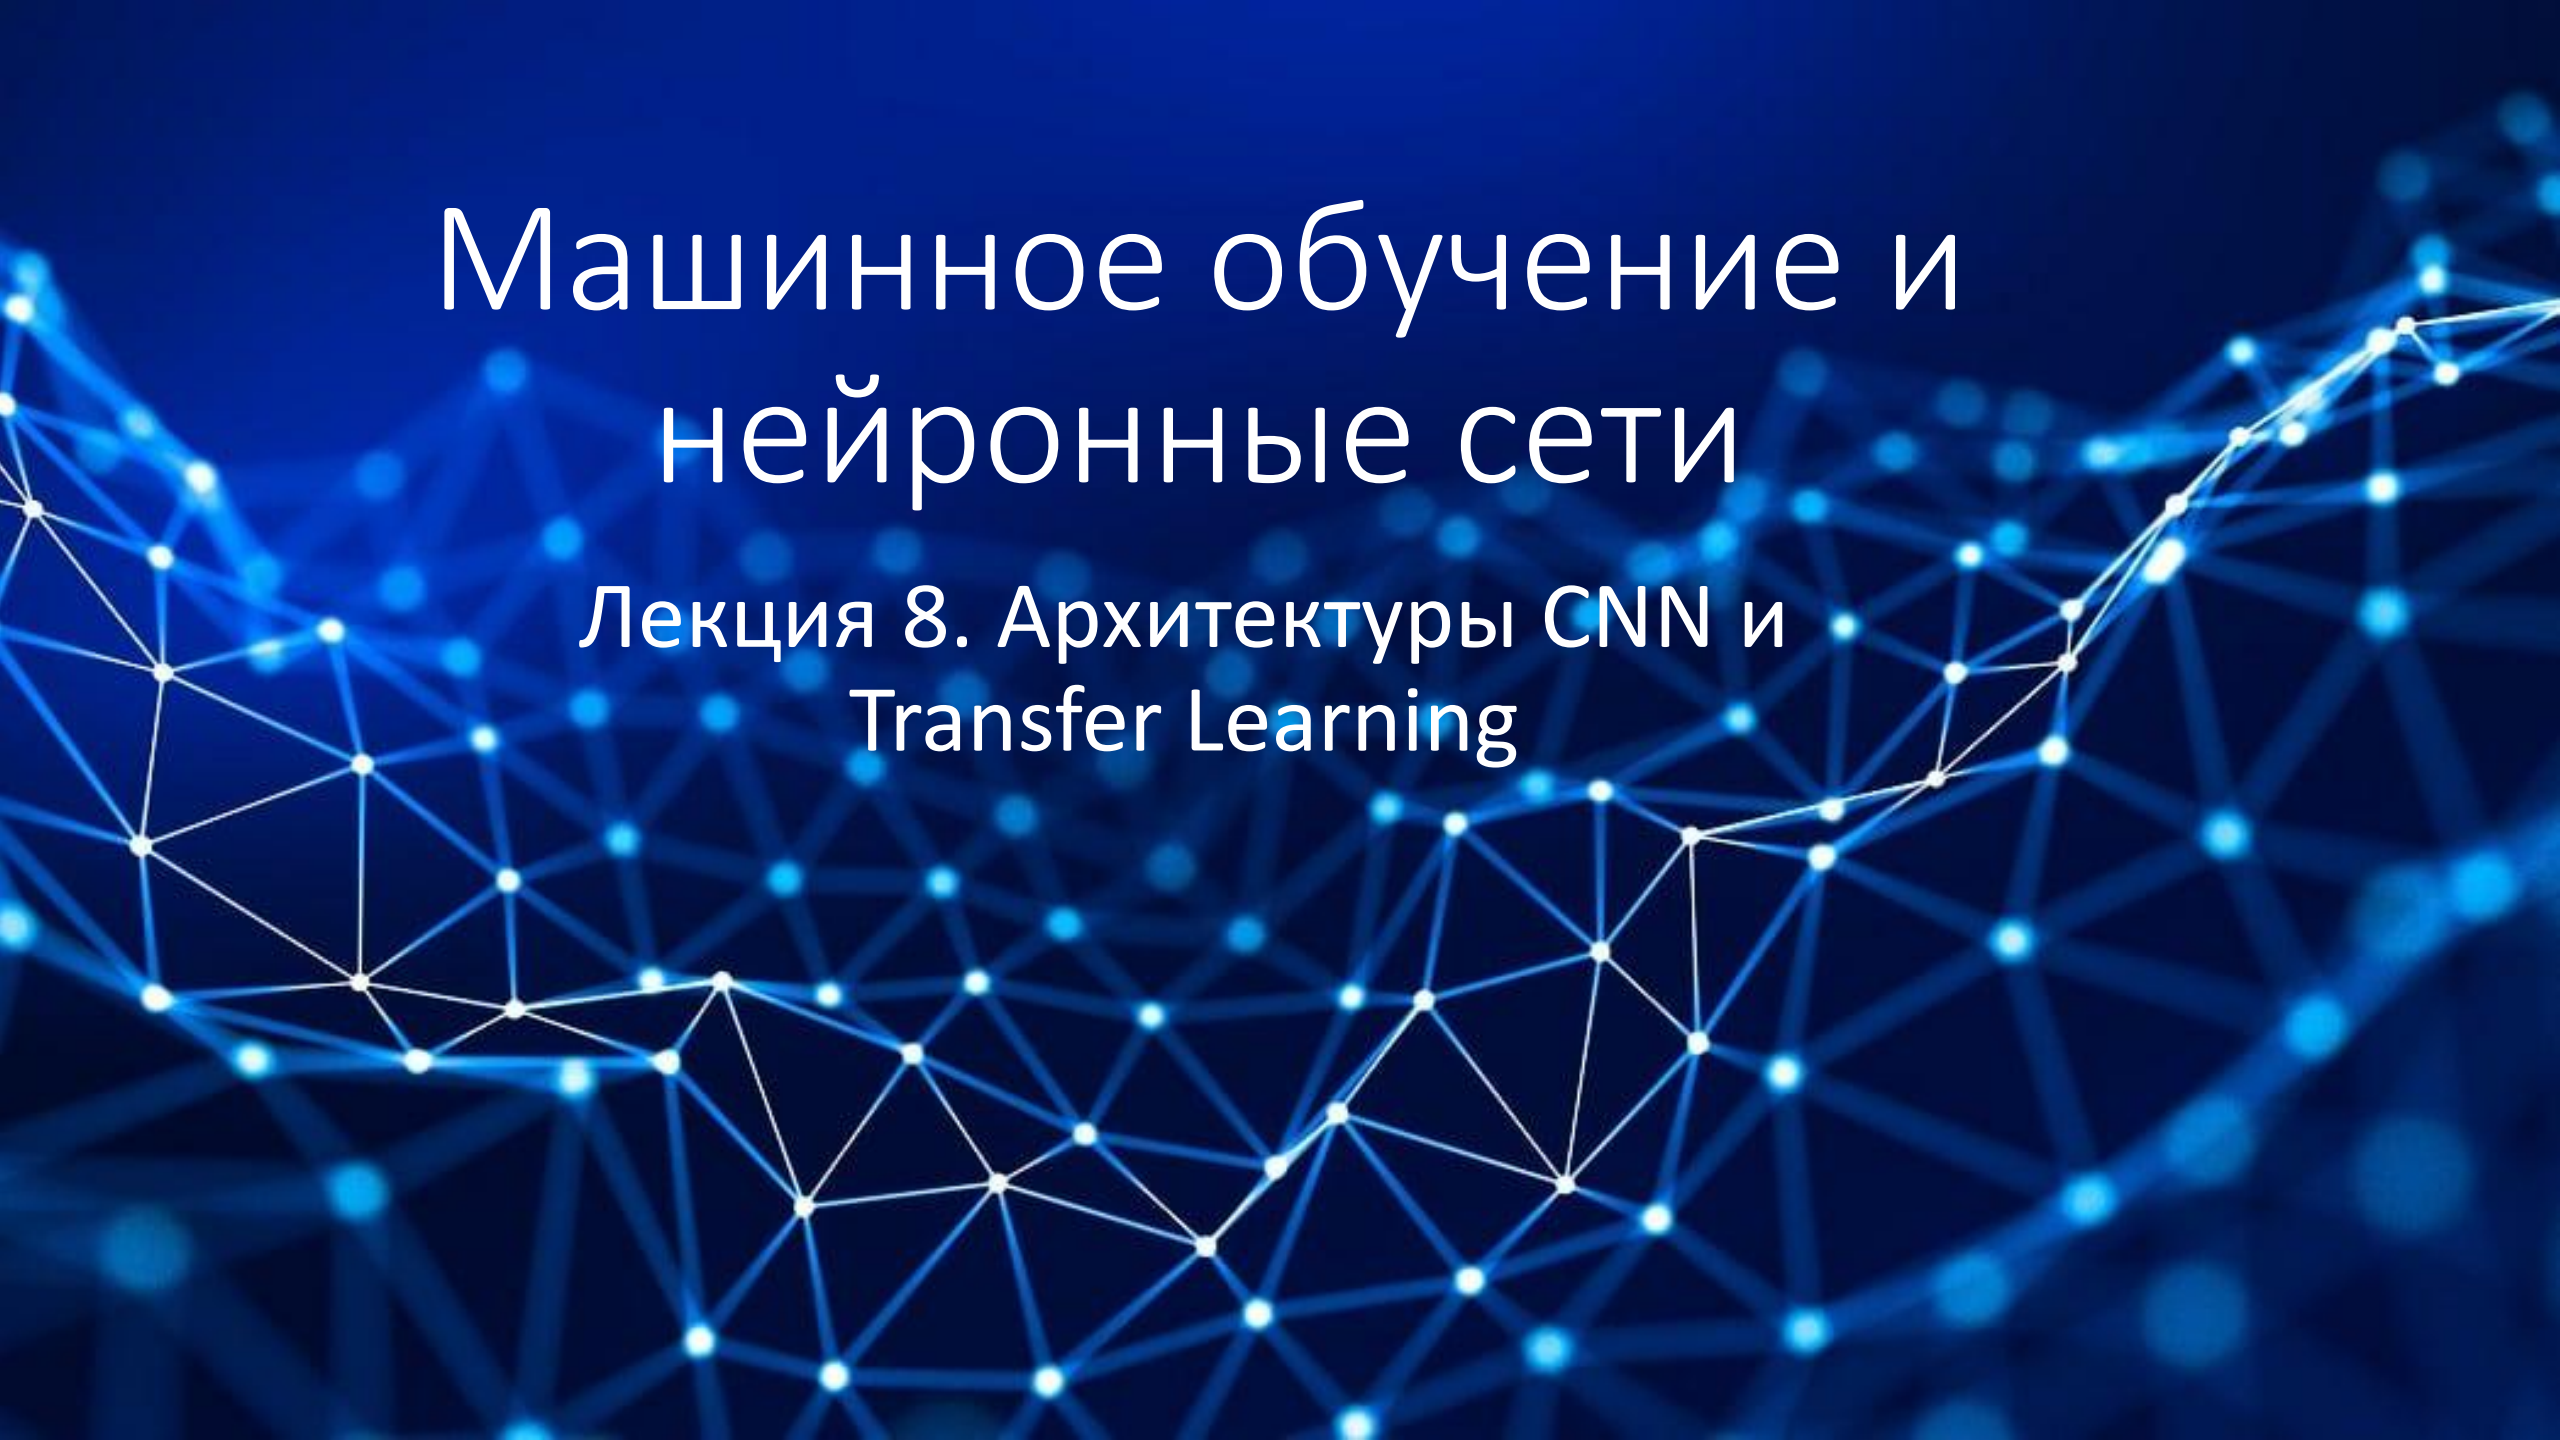

Машинное обучение и нейронные сети
Лекция 8. Архитектуры CNN и Transfer Learning

План

- Архитектуры сверточных нейросетей
- Skip connection
- Transfer Learning

CNN Architectures

IMAGENET

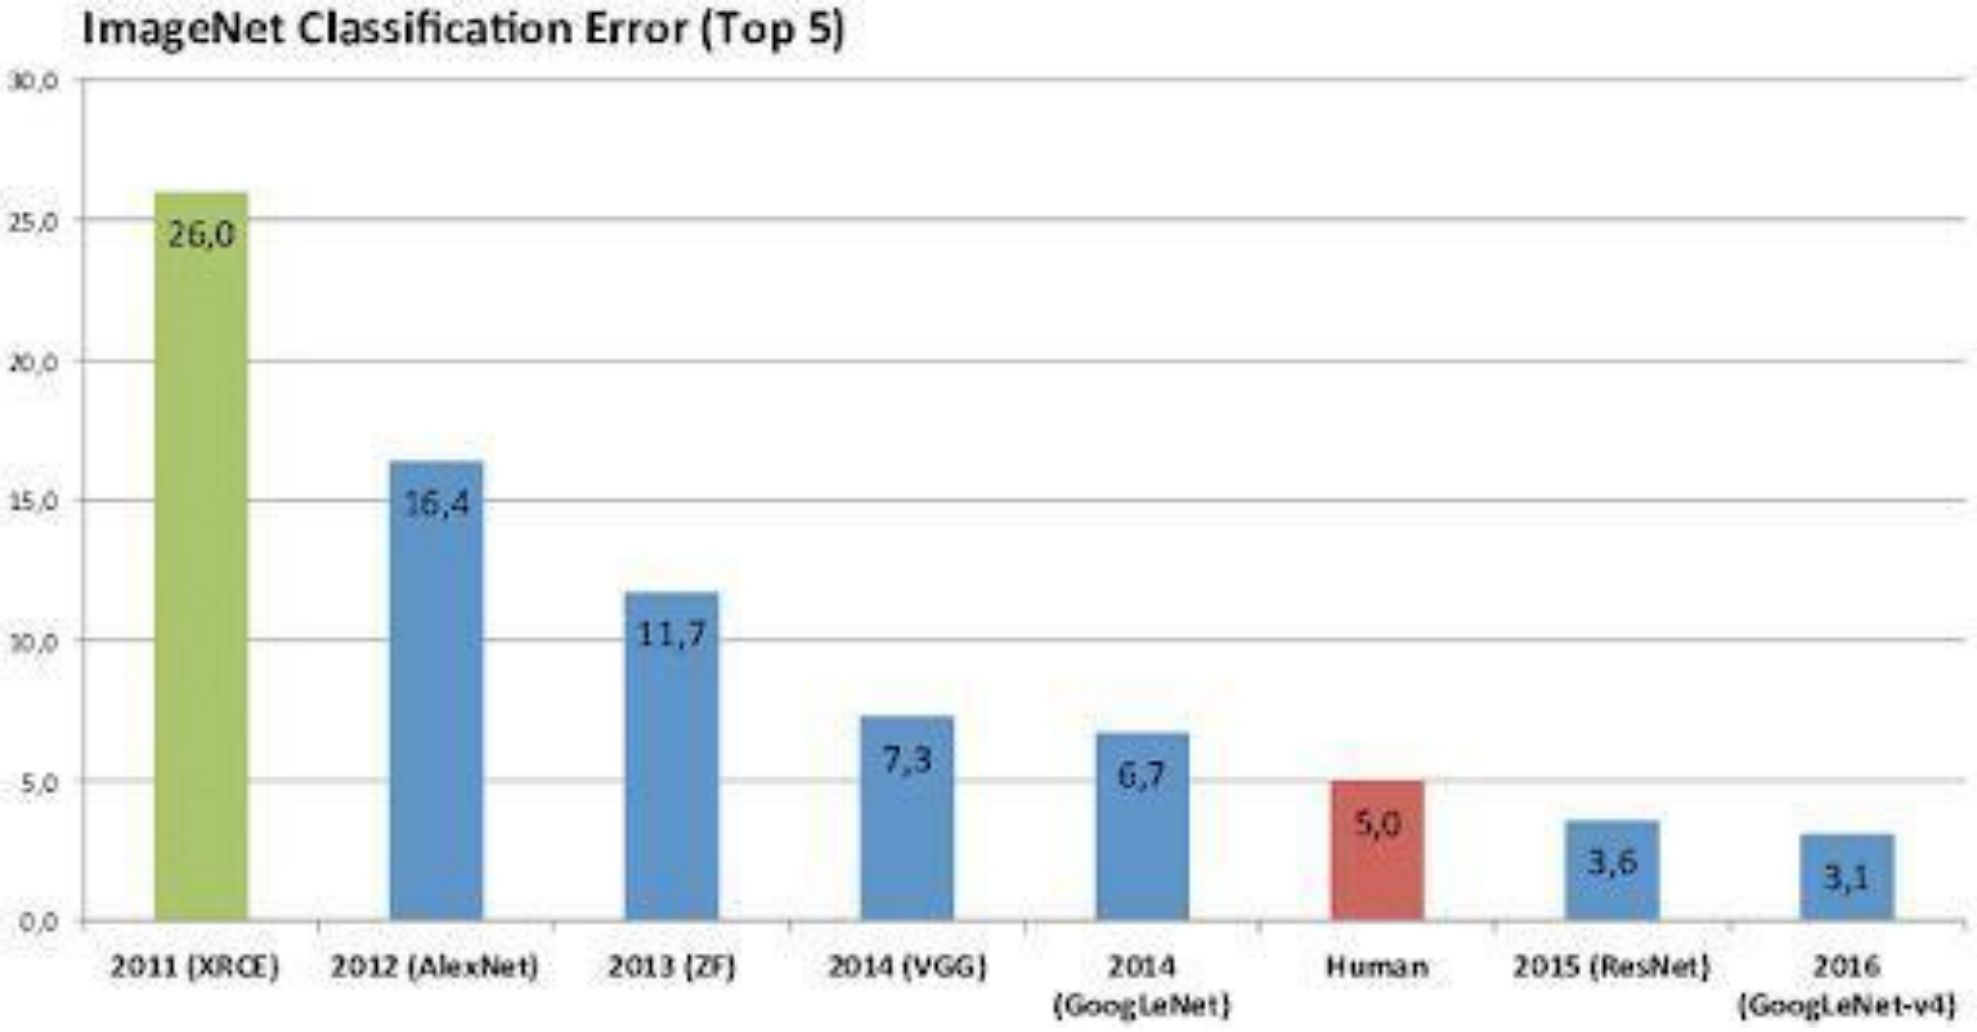
14,197,122 images, 21841 synsets indexed

Explore Download Challenges Publications Updates About

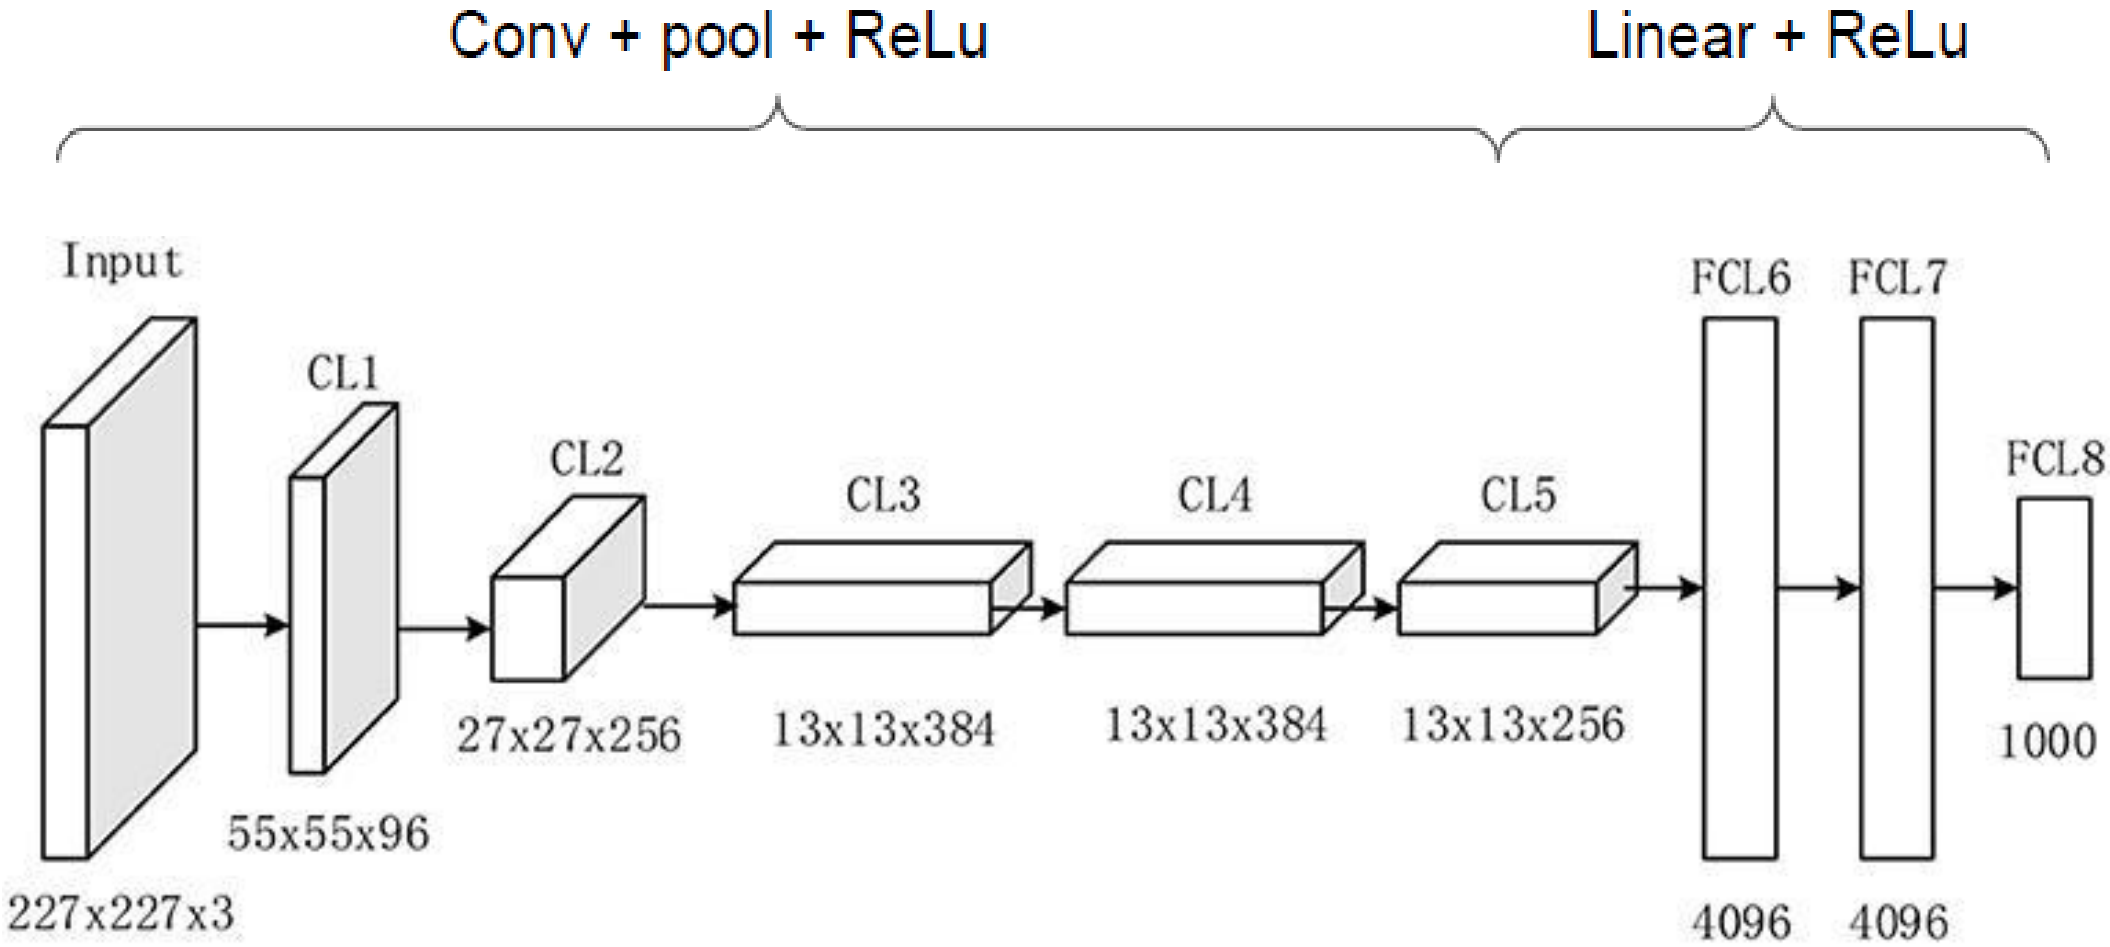
Not logged in. Login | Signup



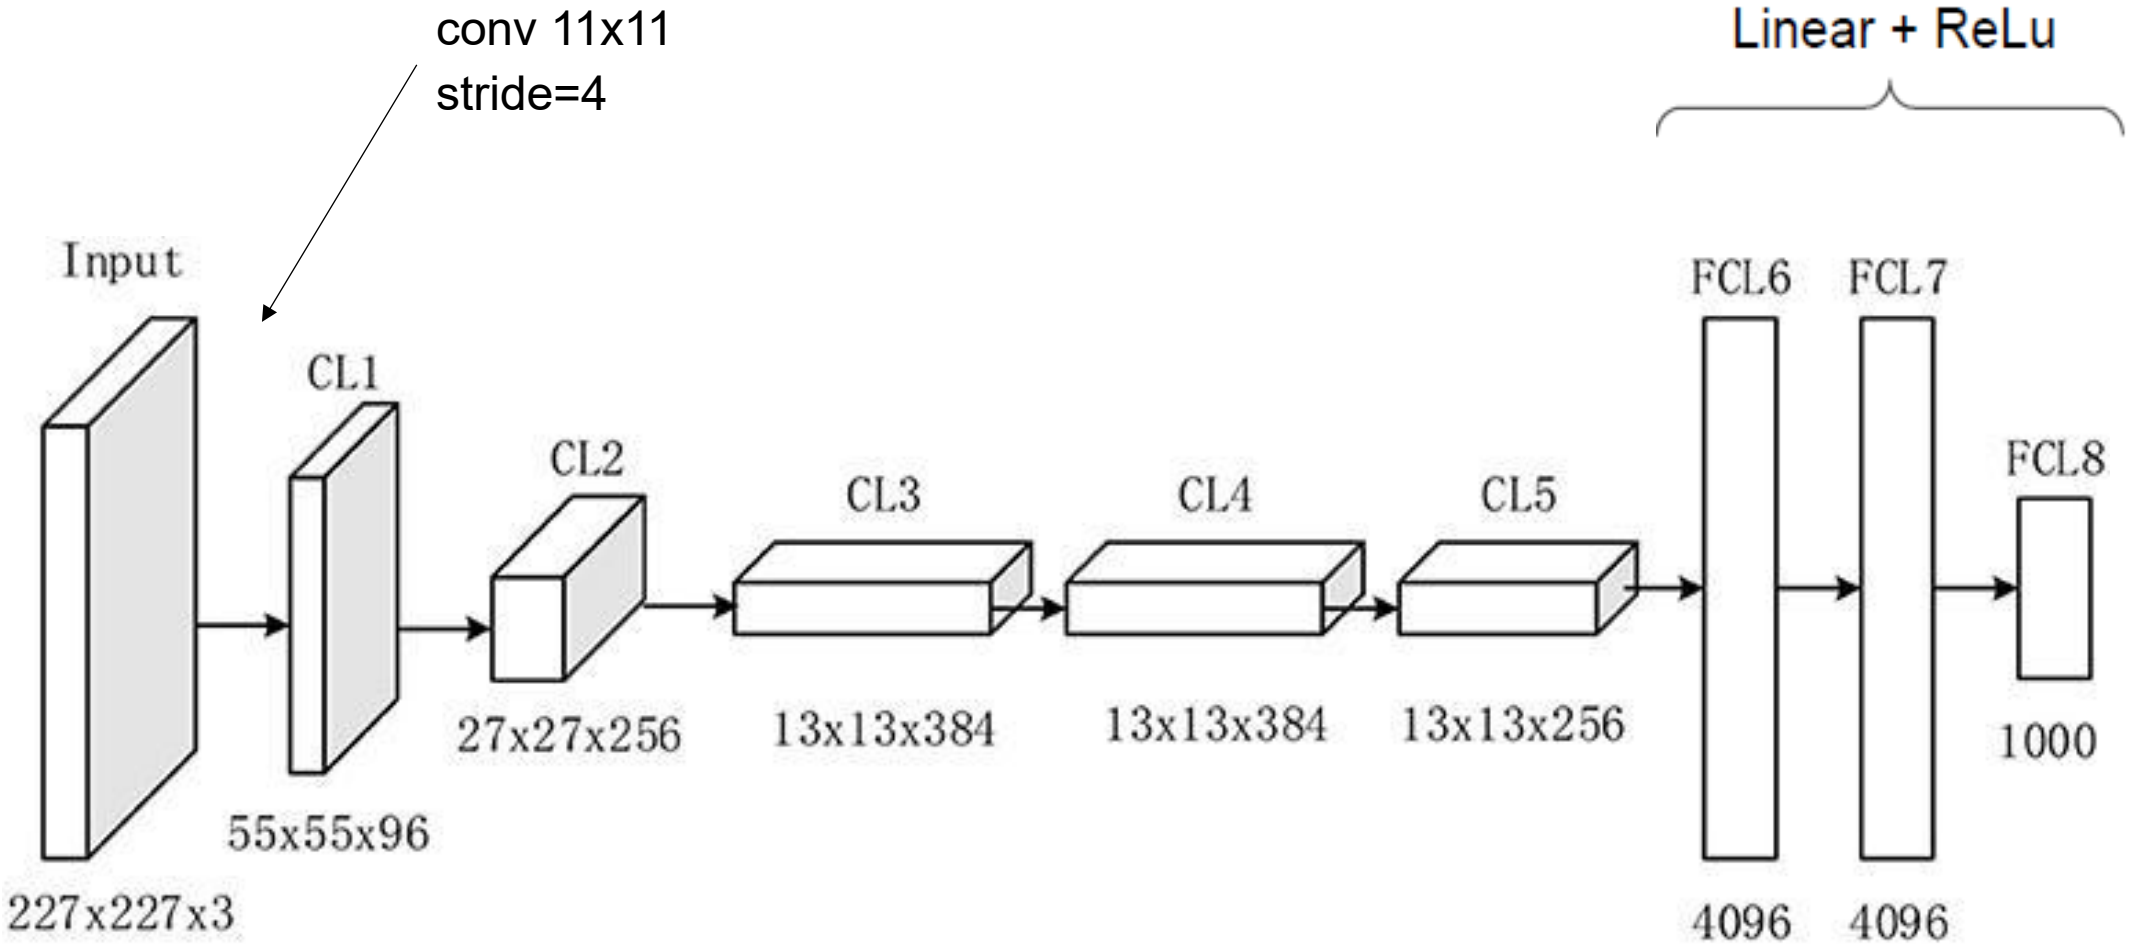
ImageNet timeline



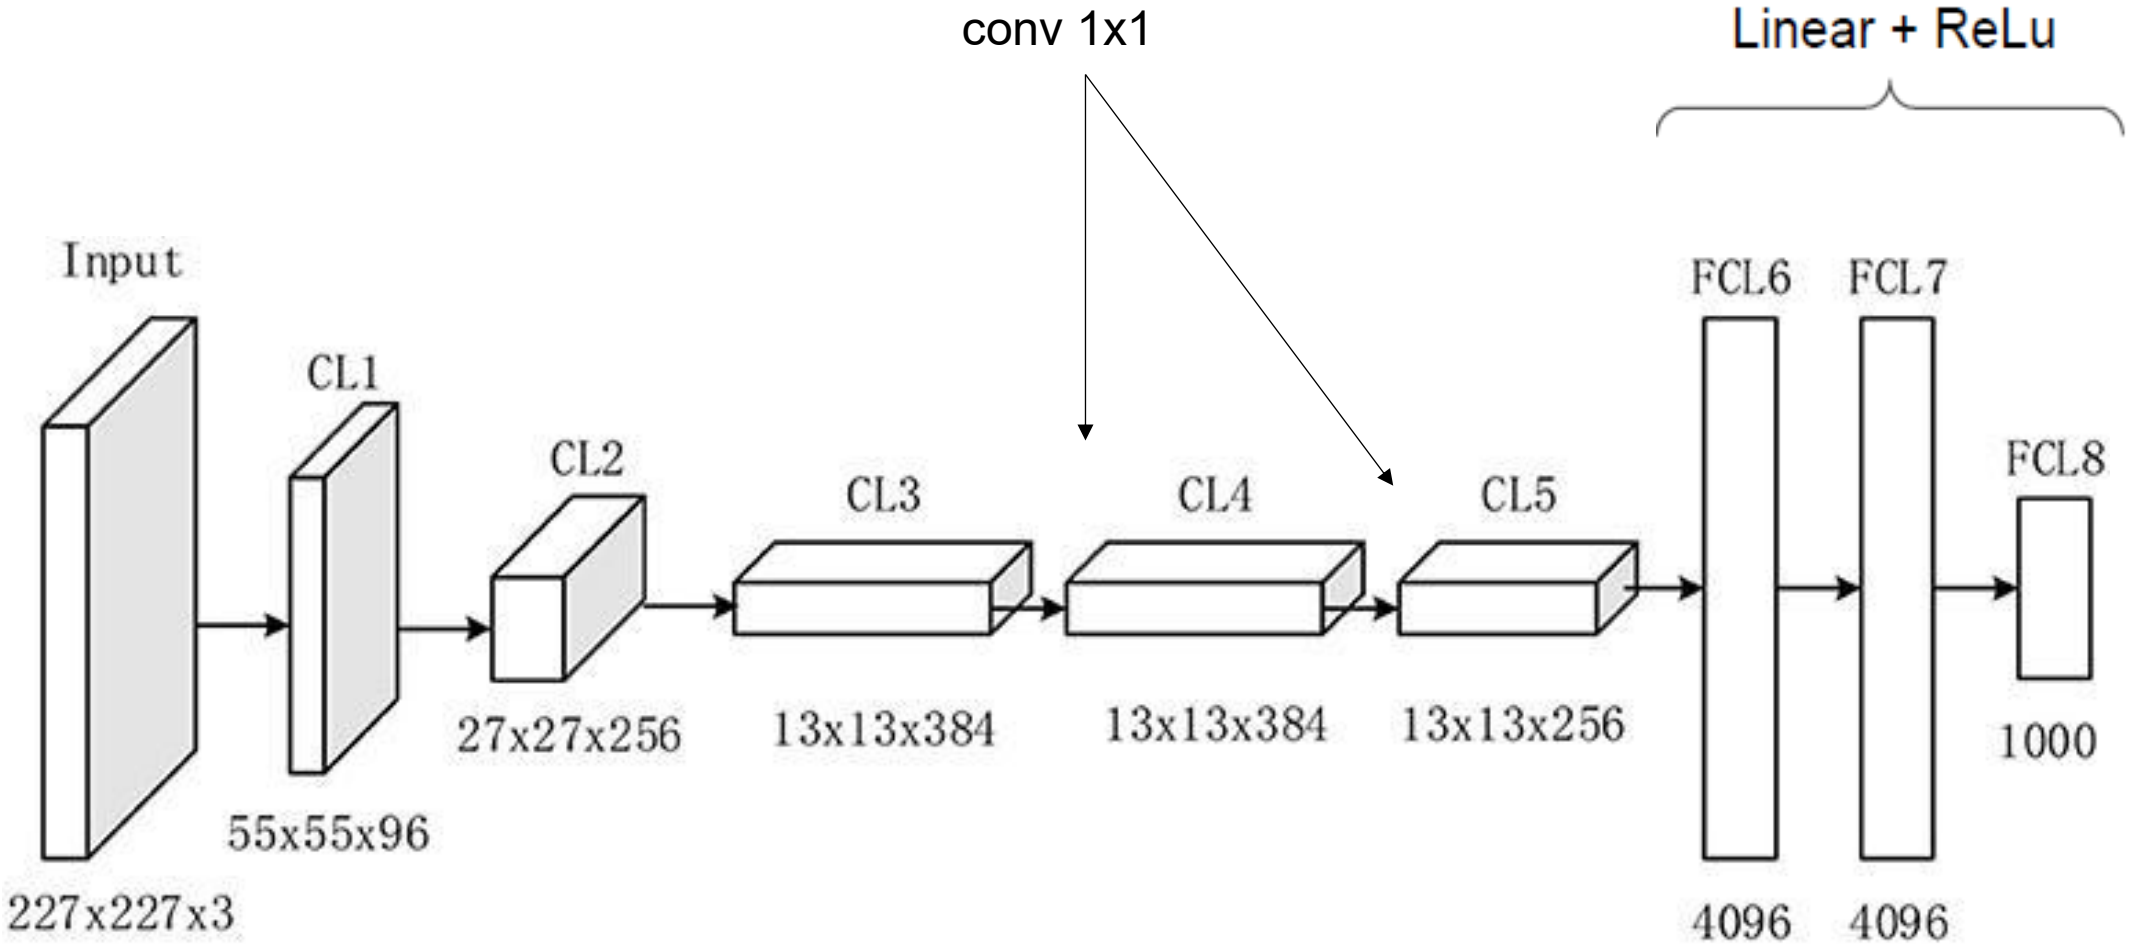
AlexNet


Conv + pool + ReLu
Linear + ReLu
Input
CL1
CL2
CL3
CL4
CL5
FCL6
FCL7
FCL8
227x227x3
55x55x96
27x27x256
13x13x384
13x13x384
13x13x256
4096
4096
1000

AlexNet


conv 11x11
stride=4
Linear + ReLu
Input
CL1
CL2
CL3
CL4
CL5
FCL6
FCL7
FCL8
227x227x3
55x55x96
27x27x256
13x13x384
13x13x384
13x13x256
4096
4096
1000

AlexNet


conv 1x1
Linear + ReLu
Input
CL1
CL2
CL3
CL4
CL5
FCL6
FCL7
FCL8
227x227x3
55x55x96
27x27x256
13x13x384
13x13x384
13x13x256
4096
4096
1000

AlexNet

Главные достижения:

- ReLU вместо Tanh
- Parallel training на нескольких GPU
- Data Augmentation

AlexNet -> VGG

- conv слои 3x3 (receptive field) - меньше, чем у AlexNet, что позволяет детектировать более низкоуровневые паттерны
- 3 fc слоя

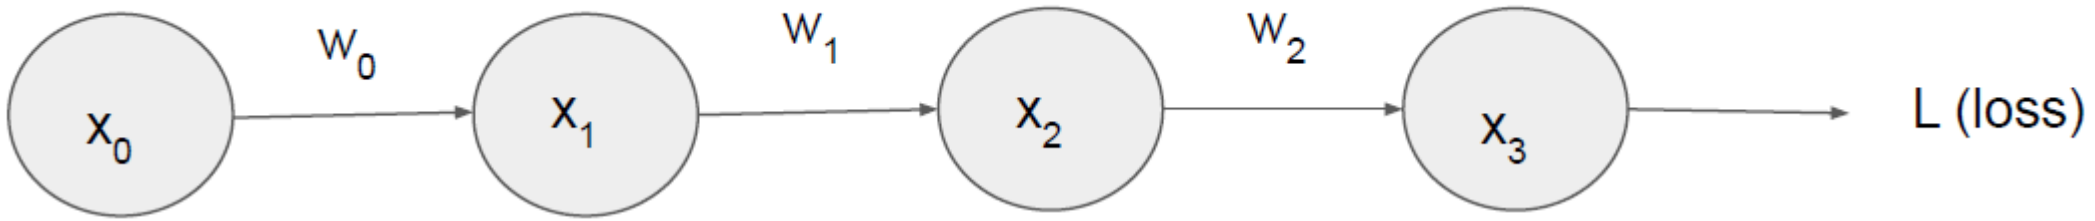


VGG

- VGG16 и VGG19 распространены больше всего

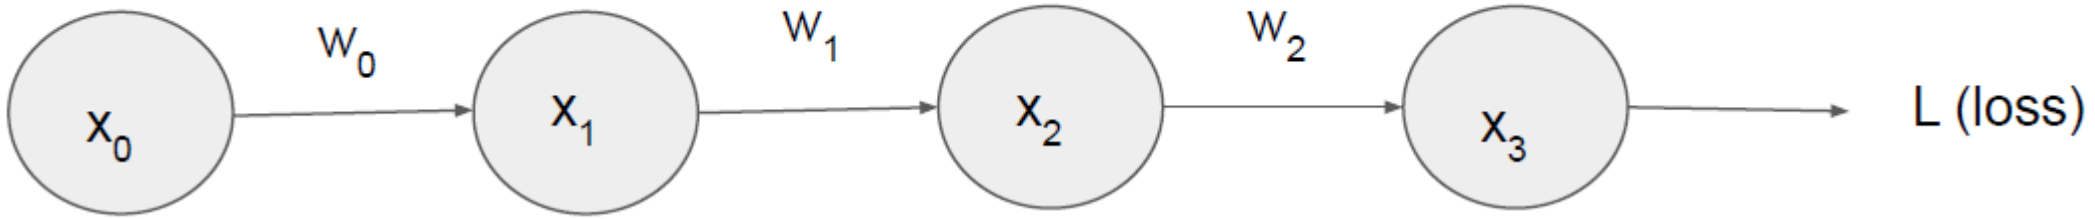
Network	Top-1 error	Top-5 error
VGG-11	30.98	11.37
VGG-13	30.07	10.75
VGG-16	28.41	9.62
VGG-19	27.62	9.12
VGG-11 with batch normalization	29.62	10.19
VGG-13 with batch normalization	28.45	9.63
VGG-16 with batch normalization	26.63	8.50
VGG-19 with batch normalization	25.76	8.15

Затухание градиентов



$$w_0 = w_0 - \alpha \frac{\delta L}{\delta w_0} \qquad w_1 = w_1 - \alpha \frac{\delta L}{\delta w_1} \qquad w_2 = w_2 - \alpha \frac{\delta L}{\delta w_2}$$

Затухание градиентов



$$w_0 = w_0 - \alpha \frac{\delta L}{\delta w_0} \qquad w_1 = w_1 - \alpha \frac{\delta L}{\delta w_1} \qquad w_2 = w_2 - \alpha \frac{\delta L}{\delta w_2}$$

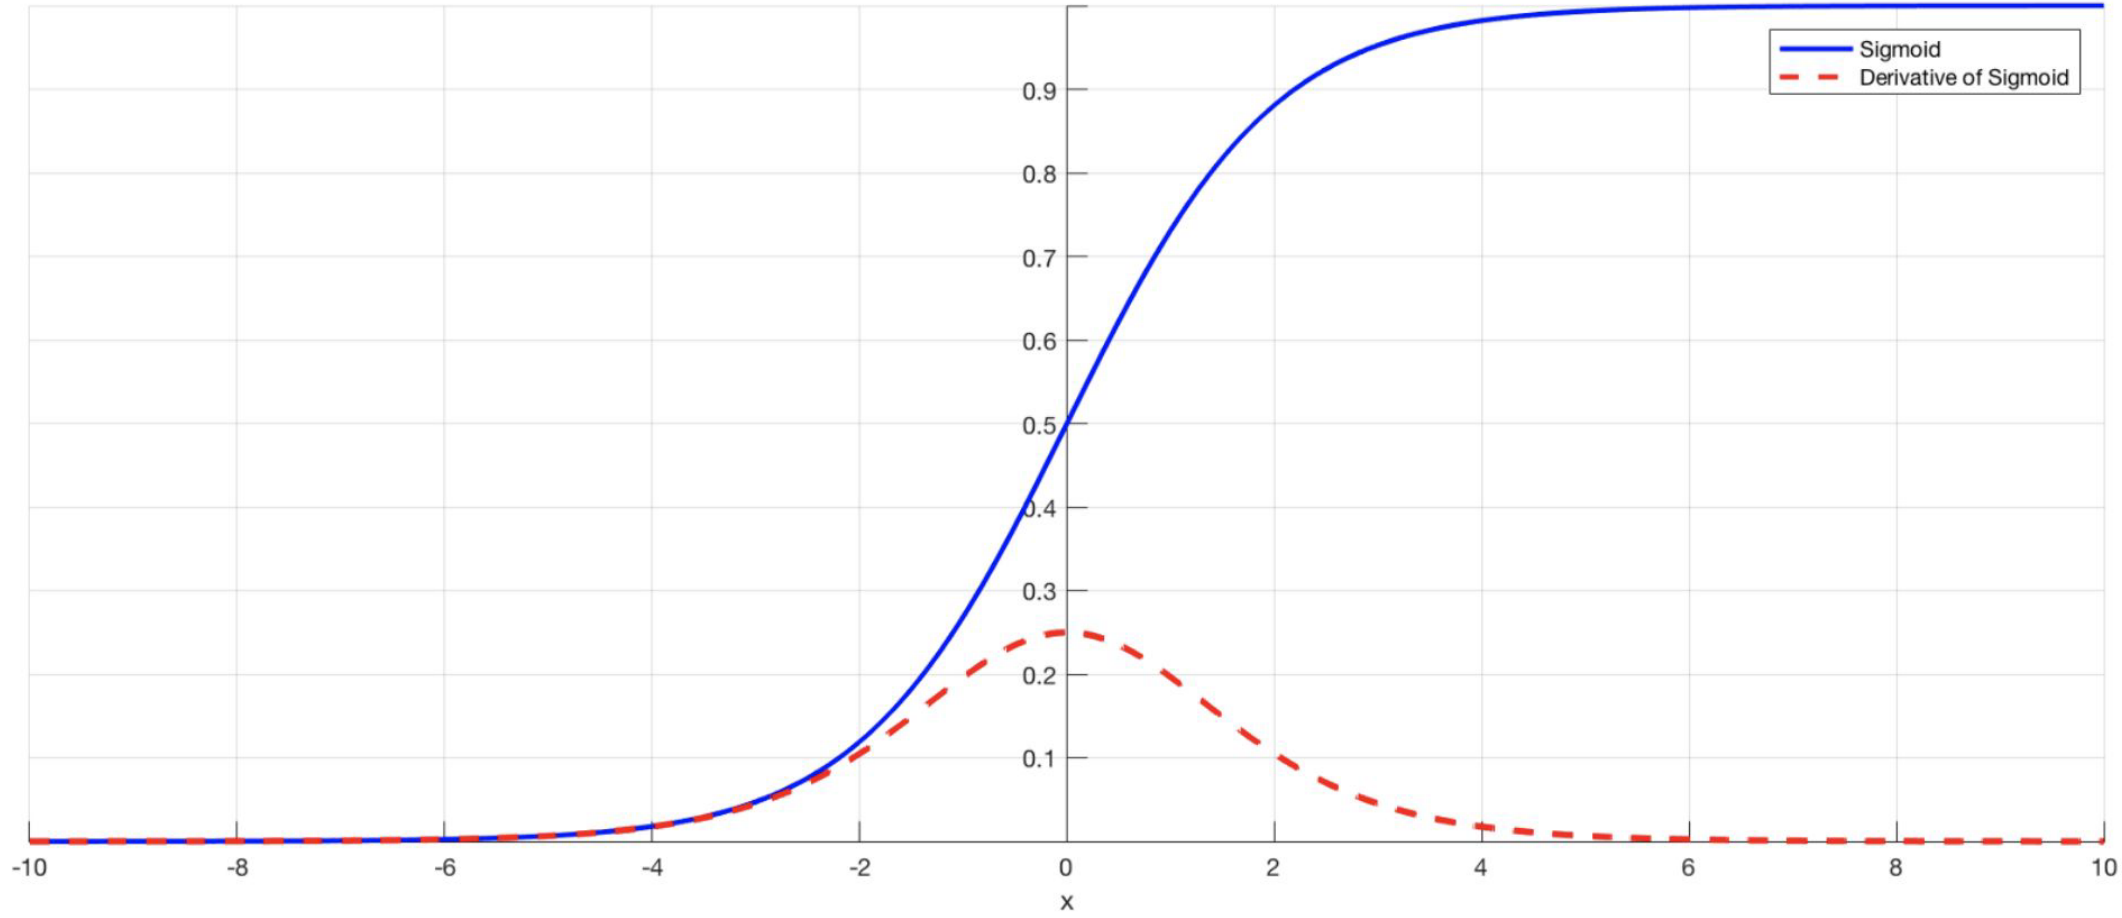
$$\frac{\delta L}{\delta w_0} = \frac{\delta L}{\delta x_3}\frac{\delta x_3}{\delta x_2}\frac{\delta x_2}{\delta x_1}\frac{\delta x_1}{\delta w_0} \qquad \frac{\delta L}{\delta w_1} = \frac{\delta L}{\delta x_3}\frac{\delta x_3}{\delta x_2}\frac{\delta x_2}{\delta w_1} \qquad \frac{\delta L}{\delta w_2} = \frac{\delta L}{\delta x_3}\frac{\delta x_3}{\delta w_2}$$

4 множителя < 1

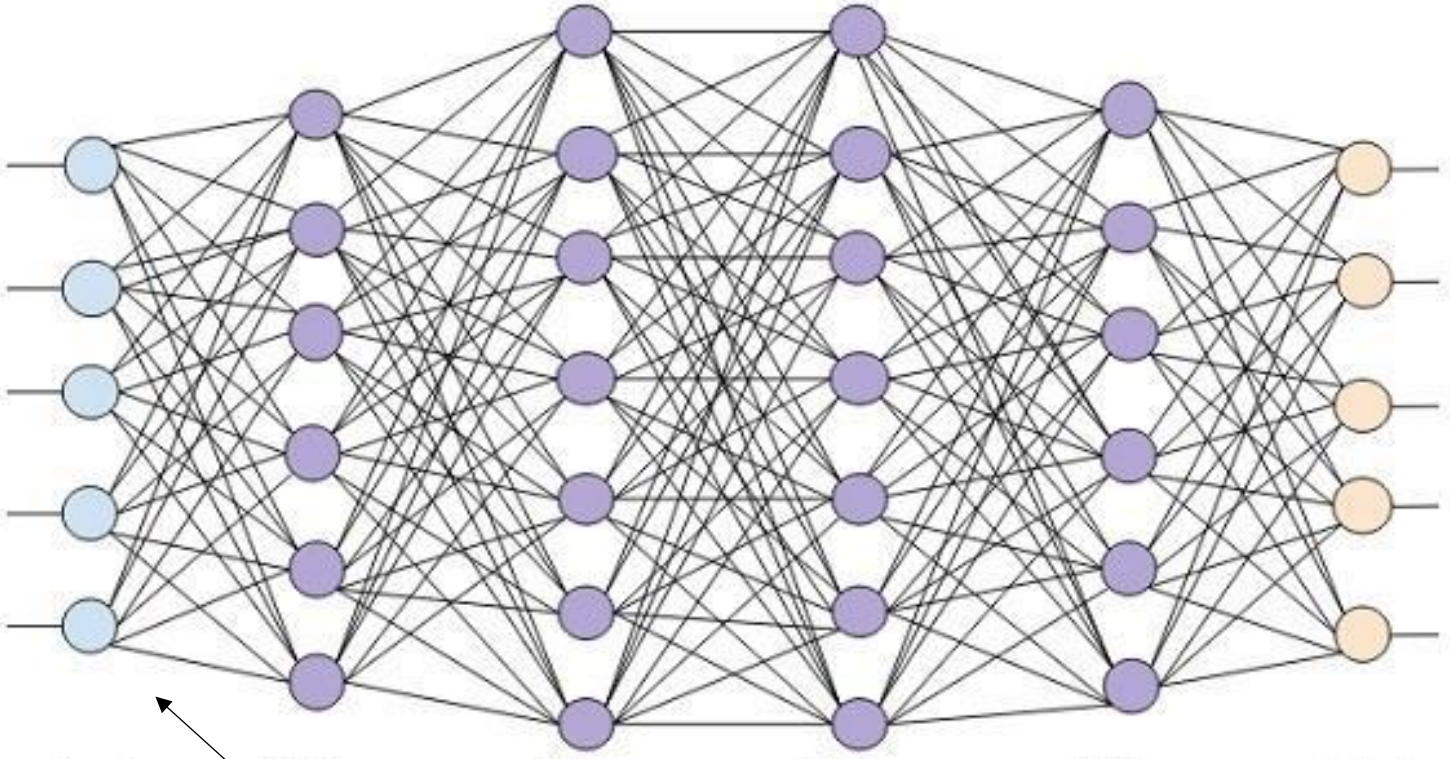
3 множителя < 1

2 множителя < 1

Затухание градиентов



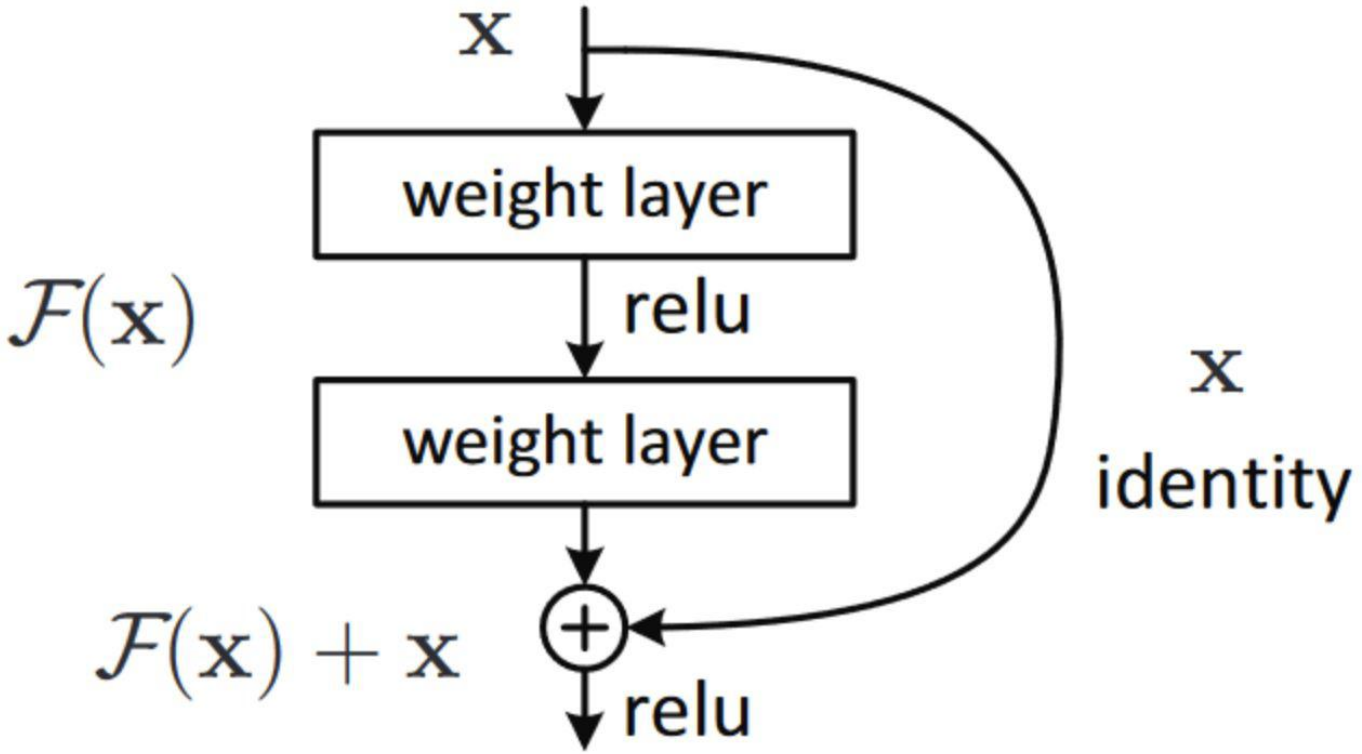
Затухание градиентов



L (loss)

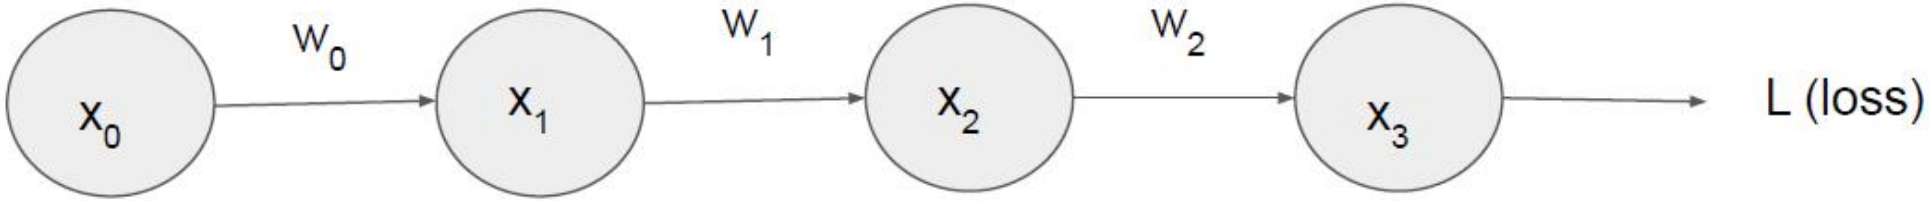
пока градиент дойдет до этого слоя, он станет очень маленьким, и веса этого слоя почти не изменятся

Skip Connection



Skip Connection

$$x_3 = x_2 w_2$$

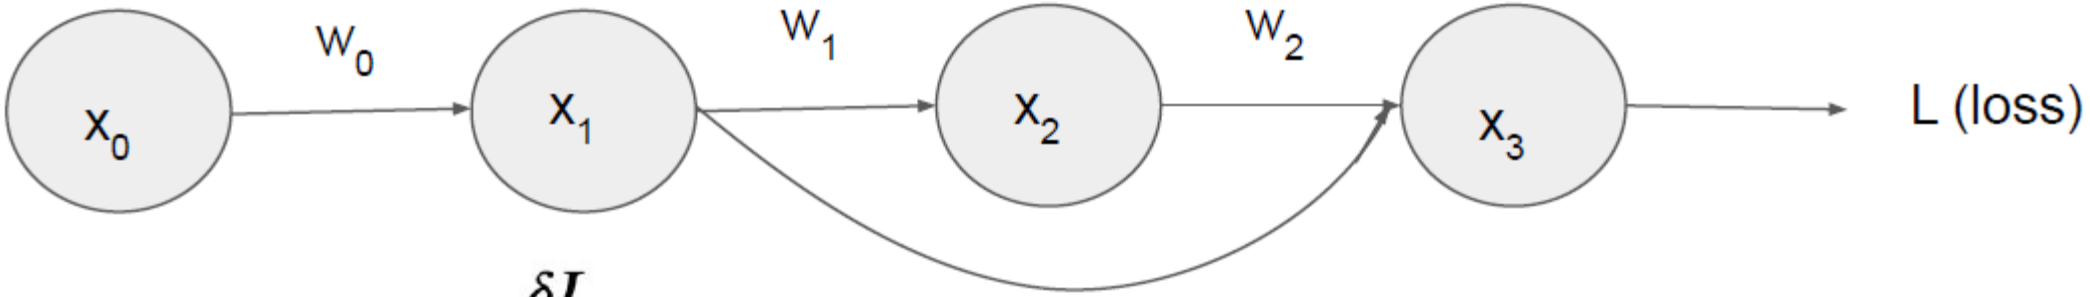


$$w_0 = w_0 - \alpha \frac{\delta L}{\delta w_0}$$

$$\frac{\delta L}{\delta w_0} = \frac{\delta L}{\delta x_3} \frac{\delta x_3}{\delta x_2} \frac{\delta x_2}{\delta x_1} \frac{\delta x_1}{\delta w_0}$$

Skip Connection

$$x_3 = x_2 w_2 + x_1$$

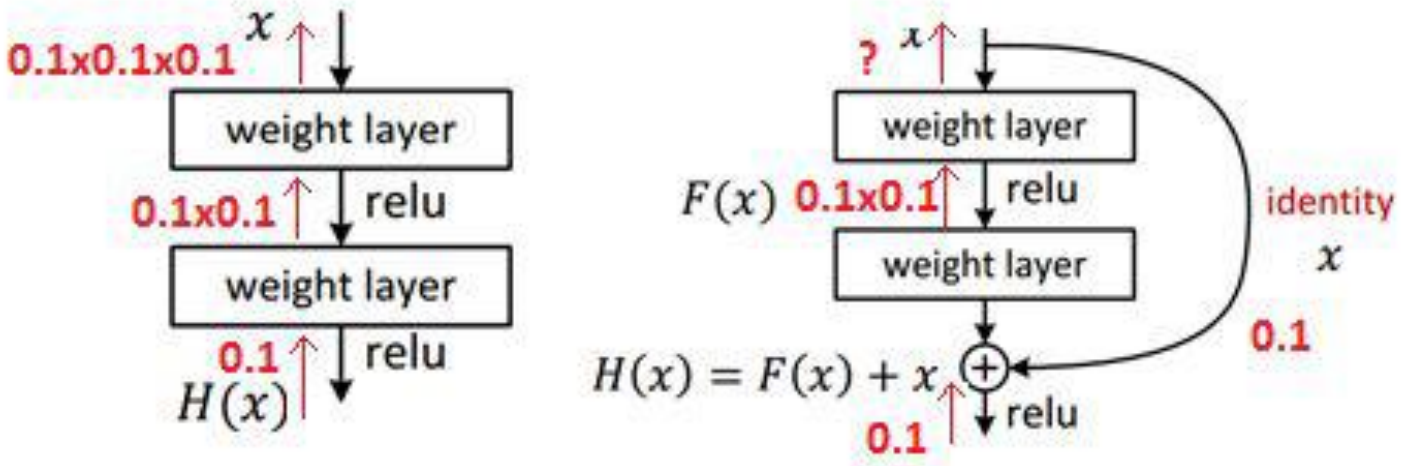


$$w_0 = w_0 - \alpha \frac{\delta L}{\delta w_0}$$

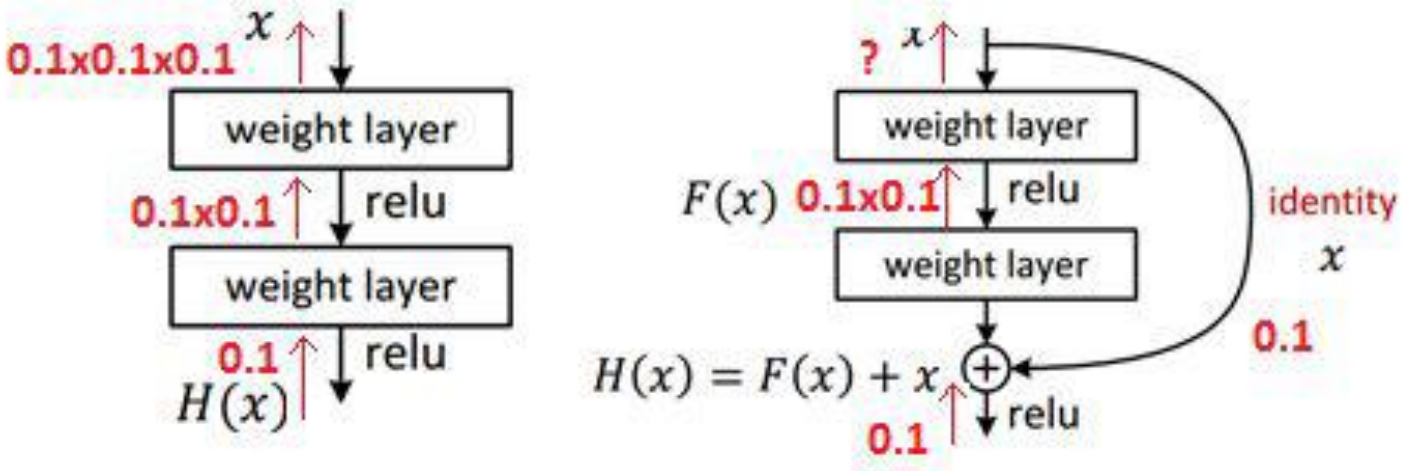
$$\frac{\delta L}{\delta w_0} = \frac{\delta L}{\delta x_3}\left(\left(\frac{\delta x_3}{\delta x_2}\frac{\delta x_2}{\delta x_1}\frac{\delta x_1}{\delta w_0}\right) + \left(\frac{\delta x_3}{\delta x_1}\frac{\delta x_1}{\delta w_0}\right)\right) =$$

$$= \frac{\delta L}{\delta x_3}\frac{\delta x_1}{\delta w_0}\left(\frac{\delta x_3}{\delta x_2}\frac{\delta x_2}{\delta x_1} + \frac{\delta x_3}{\delta x_1}\right) = \frac{\delta L}{\delta x_3}\frac{\delta x_1}{\delta w_0}\left(\frac{\delta x_3}{\delta x_2}\frac{\delta x_2}{\delta x_1} + 1\right)$$

Skip Connection



Skip Connection



Skip Connection

код очень прост

```
def forward(self, x: Tensor) -> Tensor:
    identity = x

    out = self.conv1(x)
    out = self.bn1(out)
    out = self.relu(out)

    out = self.conv2(out)
    out = self.bn2(out)

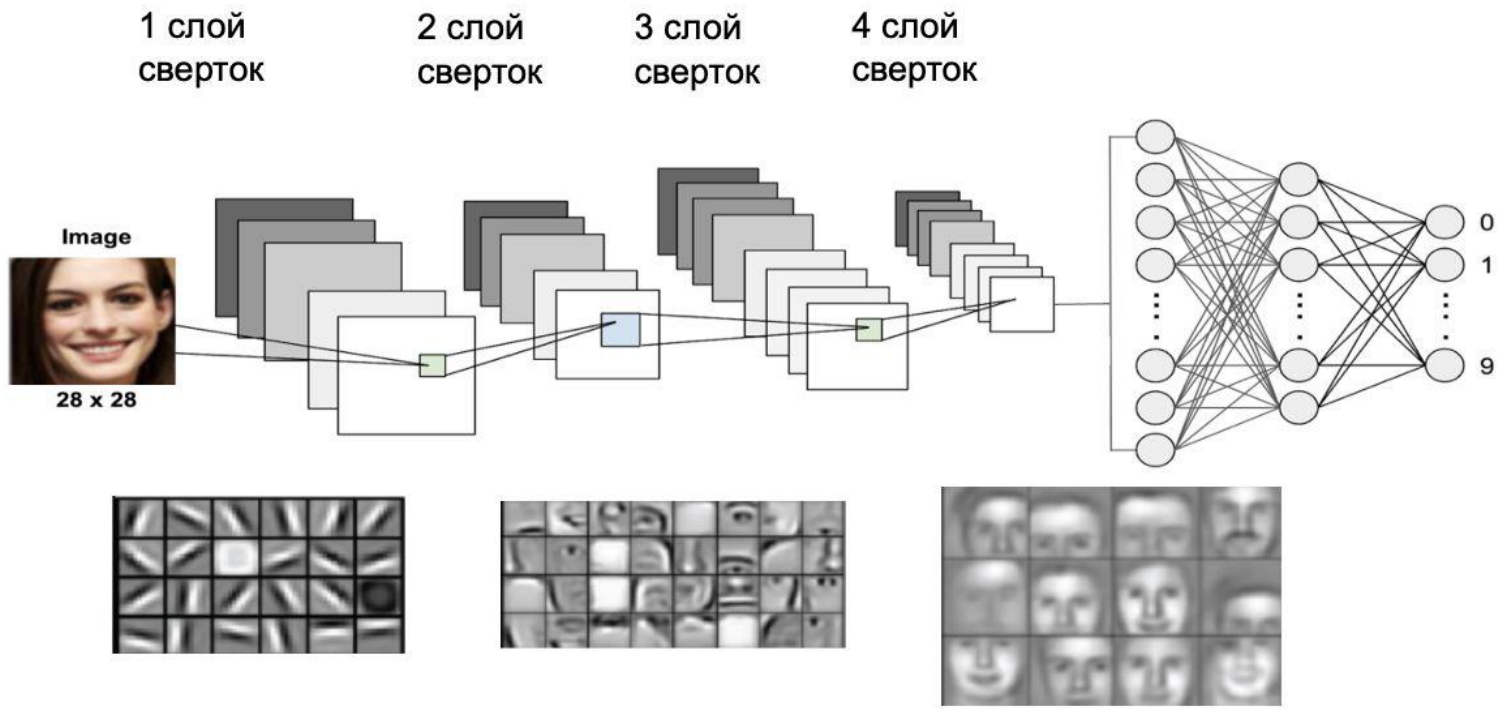
    if self.downsample is not None:
        identity = self.downsample(x)

    out += identity
    out = self.relu(out)

    return out
```

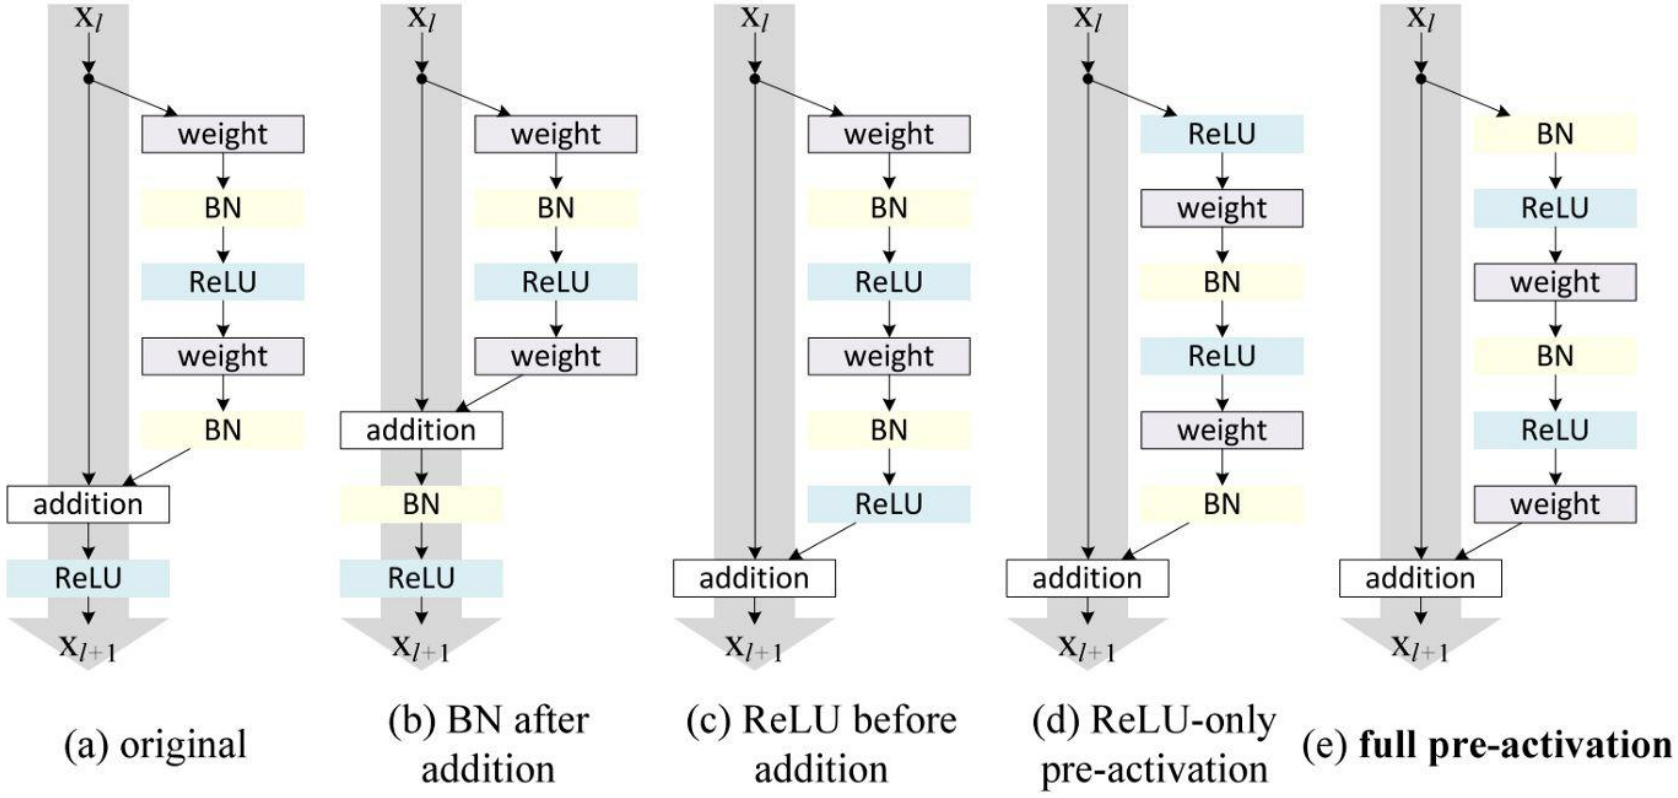
Skip connection

- используется чаще всего в CNN (включая ResNet)
- помогает в борьбе с затуханием градиентов
- помогает “протолкнуть” в нижние слои сети информацию из верхних слоев



ResNet: CNN + skip connection

Варианты ResNet Residual blocks



ResNet

```
self.conv1 = conv3x3(inplanes, planes, stride)
self.bn1 = norm_layer(planes)
self.relu = nn.ReLU(inplace=True)
self.conv2 = conv3x3(planes, planes)
self.bn2 = norm_layer(planes)
self.downsample = downsample
self.stride = stride
```

```
def forward(self, x):
    identity = x

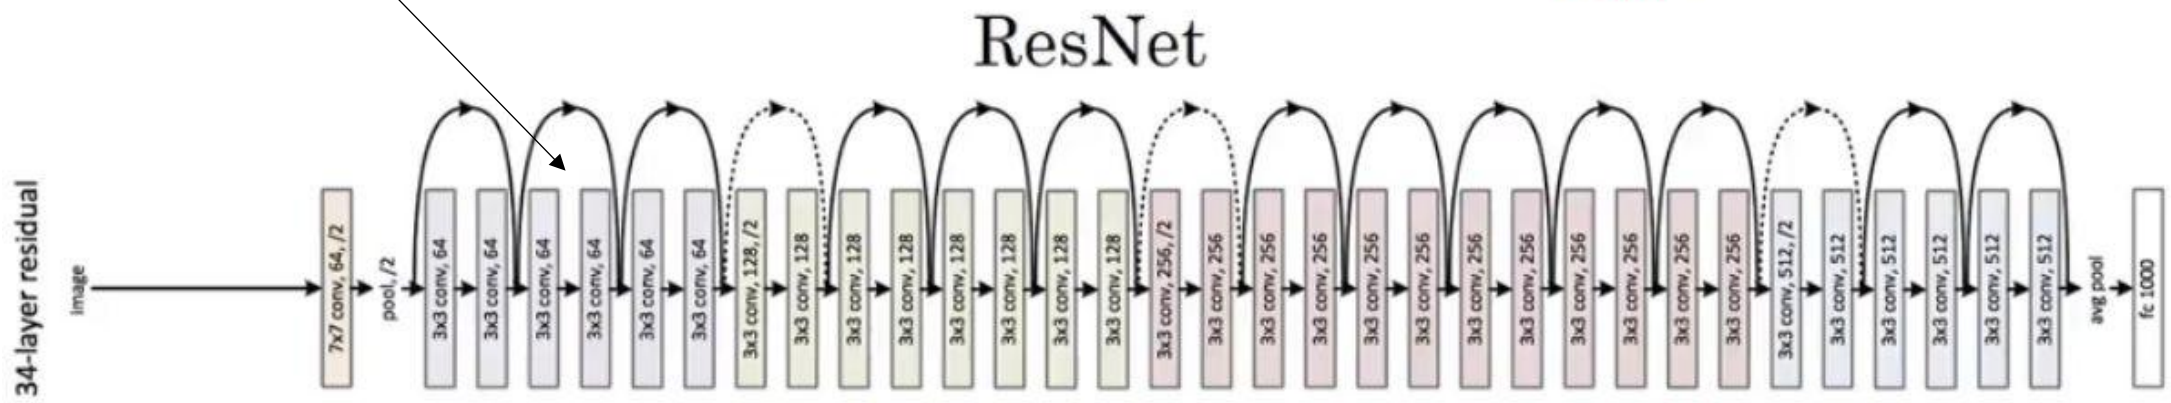
    out = self.conv1(x)
    out = self.bn1(out)
    out = self.relu(out)

    out = self.conv2(out)
    out = self.bn2(out)

    if self.downsample is not None:
        identity = self.downsample(x)

    out += identity
    out = self.relu(out)

    return out
```



ResNet

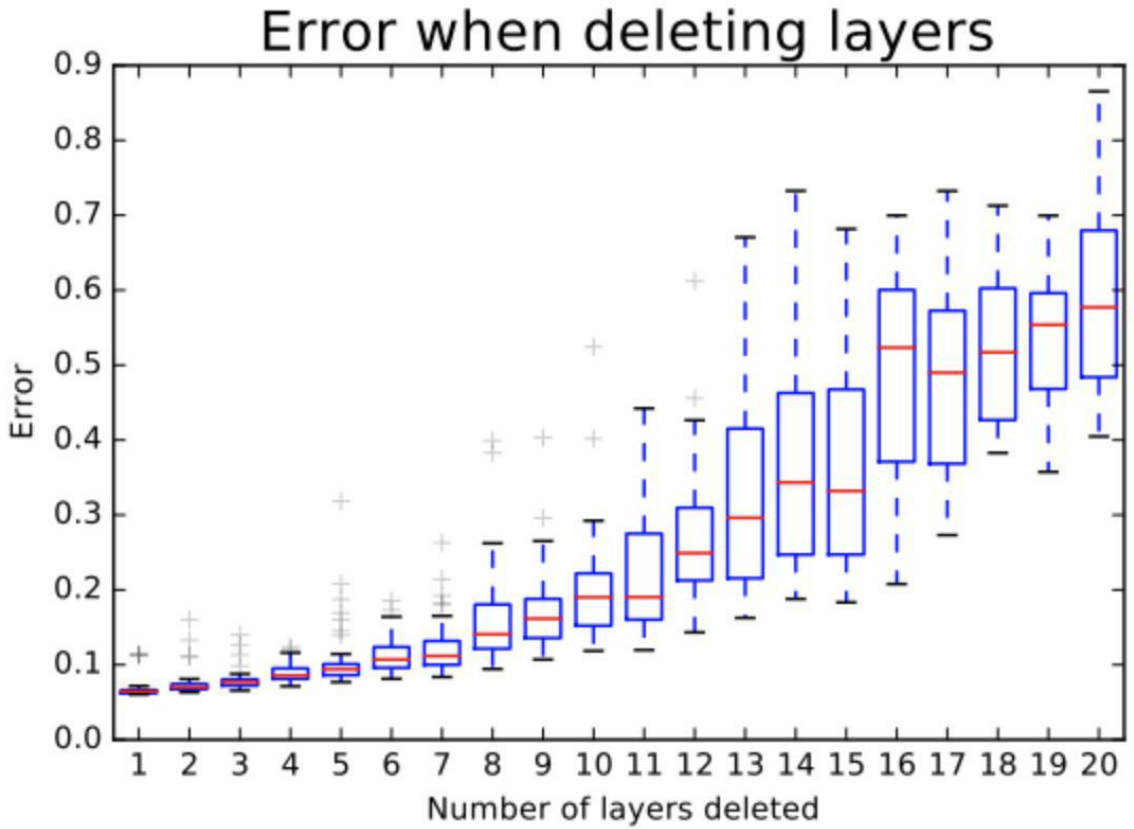
- ResNet-18
- ResNet-34
- ResNet-49
- ResNet-50
- ResNet-74
- ResNet-90
- ResNet-100
- ResNet-101
- ResNet-152

Network	Top-1 error	Top-5 error
ResNet-18	30.24	10.92
ResNet-34	26.70	8.58
ResNet-50	23.85	7.13
ResNet-101	22.63	6.44
ResNet-152	21.69	5.94

ResNet

Интересный факт: из ResNet можно выкинуть несколько слоев и ее performance снизится не слишком сильно.

Это достигается тем, что у ResNet есть “обходные пути” для информации (skip-connection), и при прерывании одного из них информация все еще может пройти по другому



DenseNet

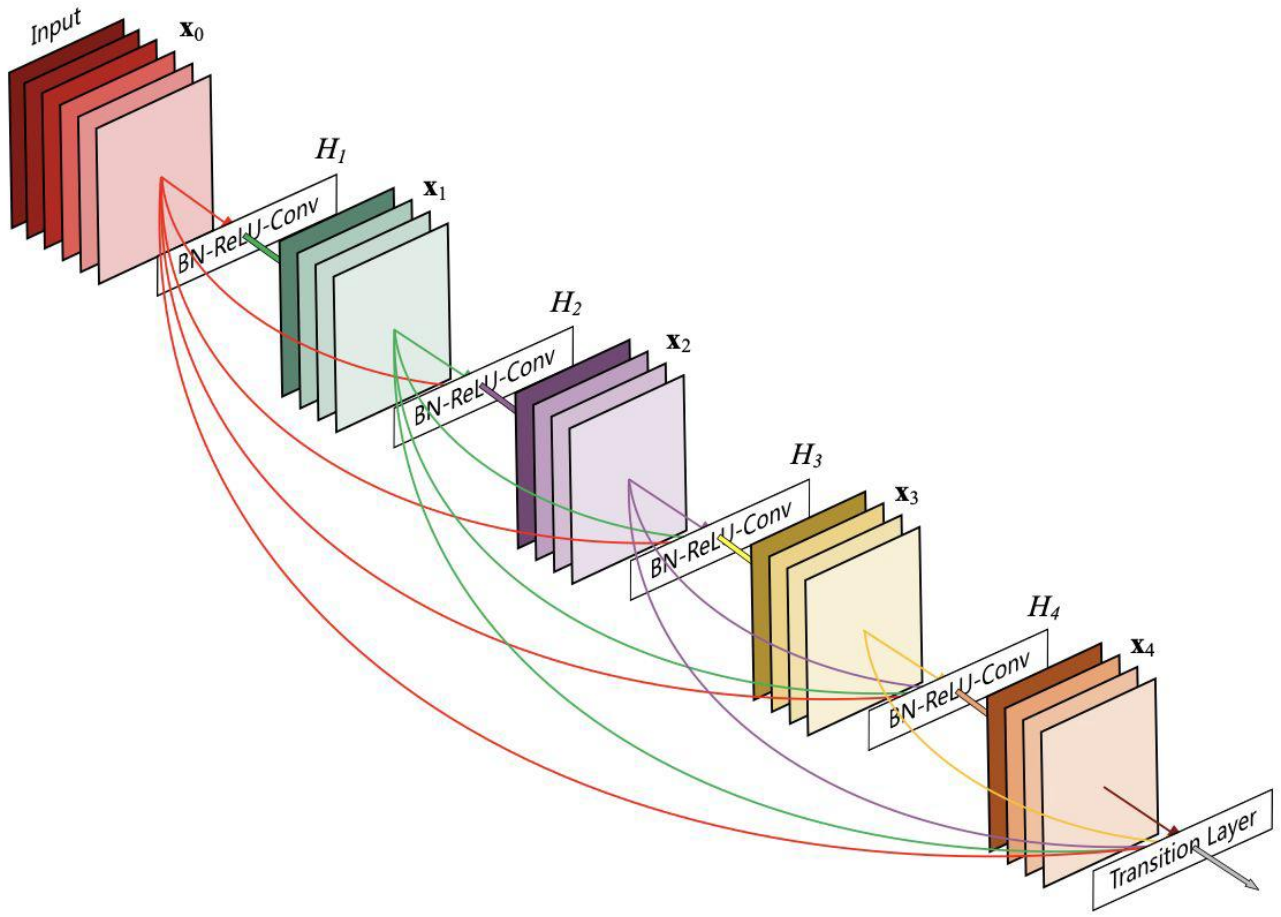
DenseBlock:

Каждый последующий слой сети получает на вход все выходы всех предыдущих сетей

DenseNet

Dense Block c growth rate = 4

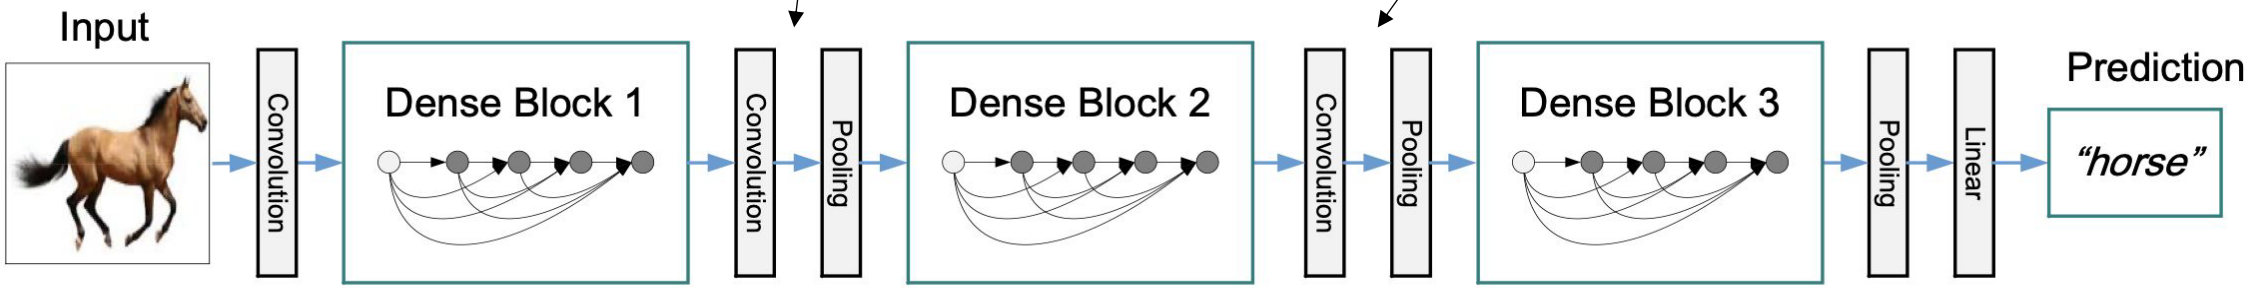
BN-relu-3x3 conv



DenseNet

Transition layers:

1x1 conv + pooling, чтобы добиться одинаковой размерности карт активаций на входе каждого dense block’a



(+relu, BN & 1x1 conv после каждой свертки внутри блока)

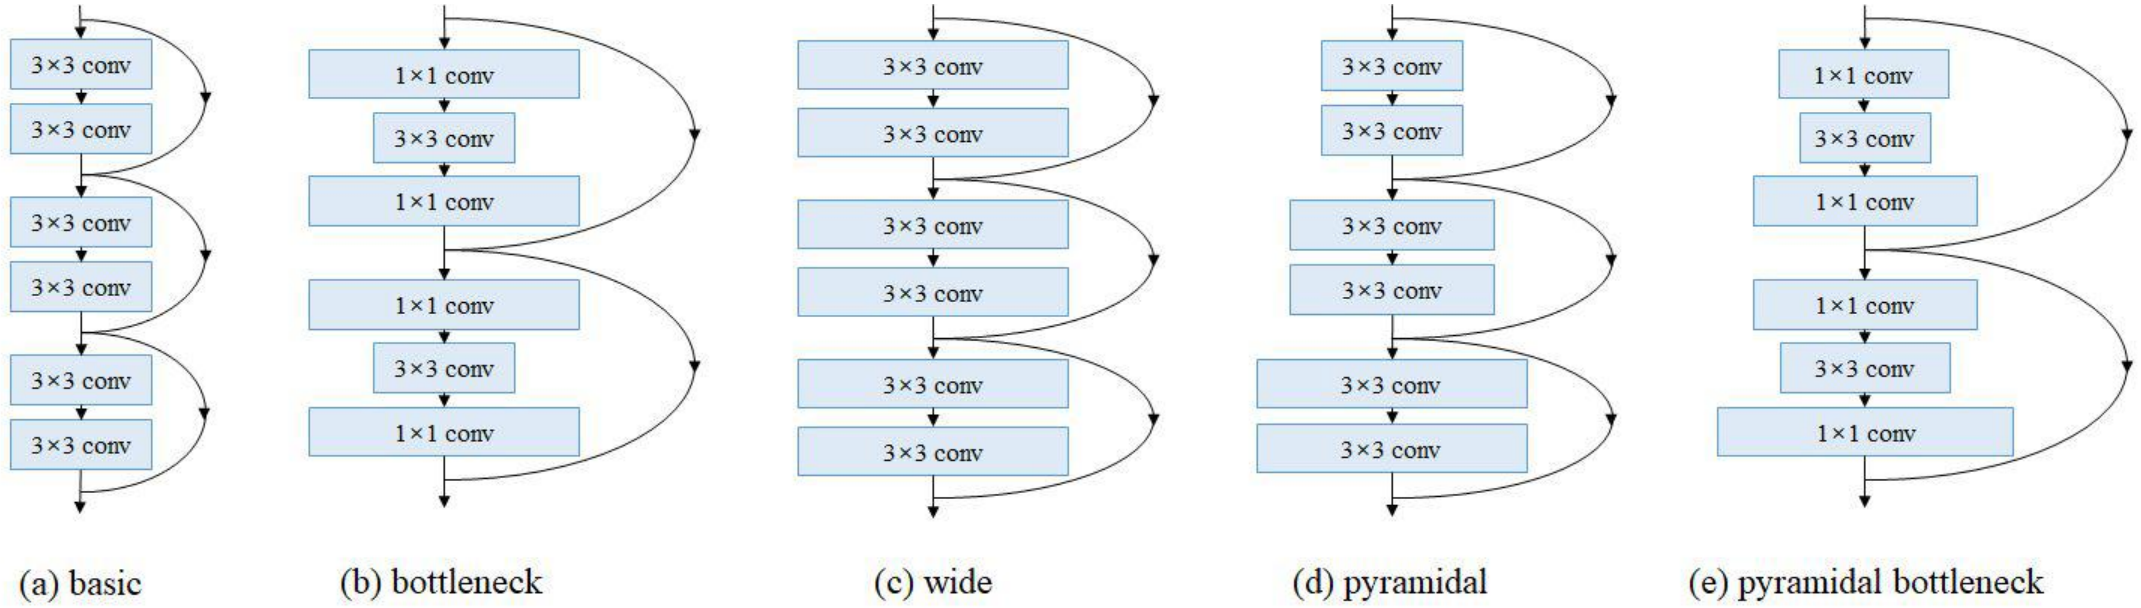
DenseNet

- strong gradient flow
- количество слоев и параметров не очень большое
- conv слои выделяют более разнообразные фичи
- нижние conv слои принимают во внимание low-complex паттерны из более верхних слоев, которые могут быть полезны для детекции некоих low-level паттернов.
  Также это помогает DenseNet лучше обучаться на маленьких датасетах.

Bottleneck Block

ResNet и DenseNet состоят из блоков.

Блоки, конечно, могут иметь разную архитектуру, не только ту, что мы рассматривали выше.



(a) basic (b) bottleneck (c) wide (d) pyramidal (e) pyramidal bottleneck

Часто используемые стандартные архитектуры сетей для классификации

TORCHVISION.MODELS

The models subpackage contains definitions of models for addressing different tasks, including: image classification, pixelwise semantic segmentation, object detection, instance segmentation, person keypoint detection and video classification.

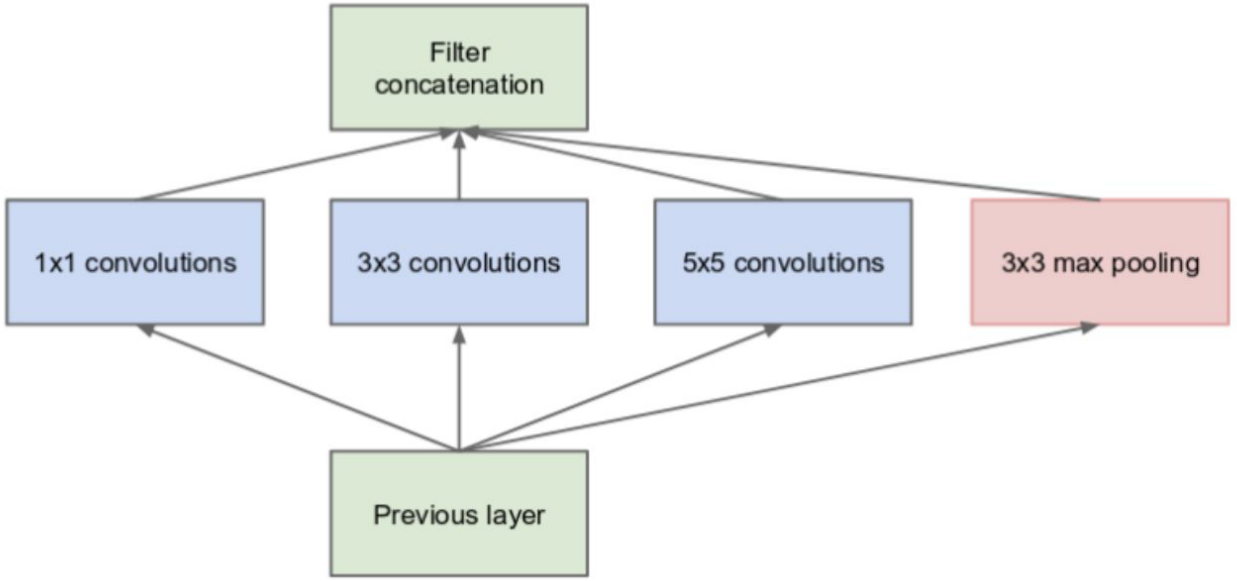
Classification

The models subpackage contains definitions for the following model architectures for image classification:

- AlexNet
- VGG
- ResNet
- SqueezeNet
- DenseNet
- Inception v3
- GoogLeNet
- ShuffleNet v2
- MobileNet v2
- ResNeXt
- Wide ResNet
- MNASNet

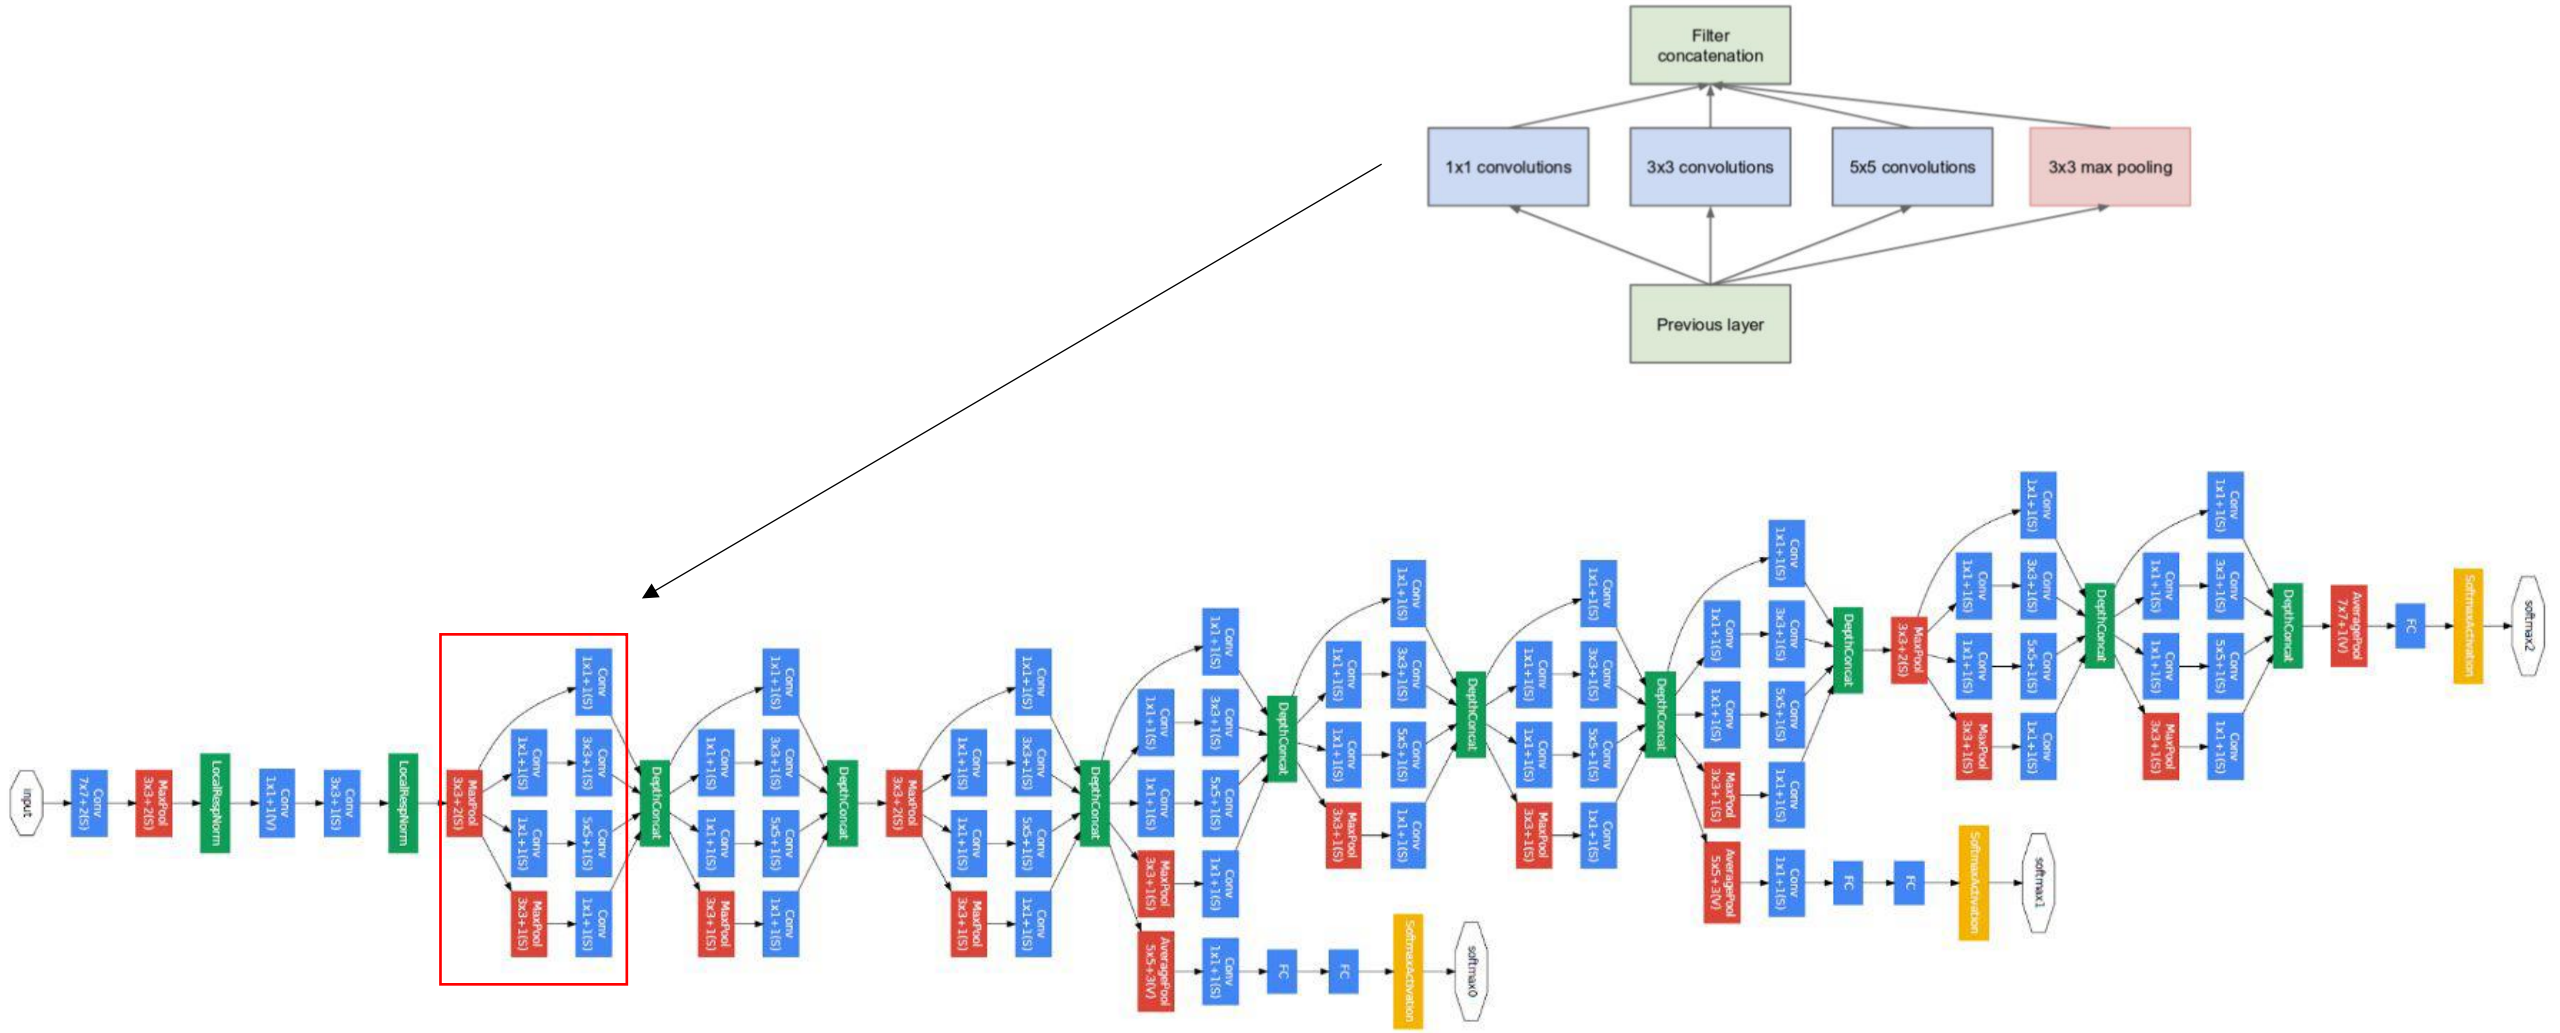
Inception

Идея: сделать несколько сверточные слоев с разными размерами фильтров на одном уровне



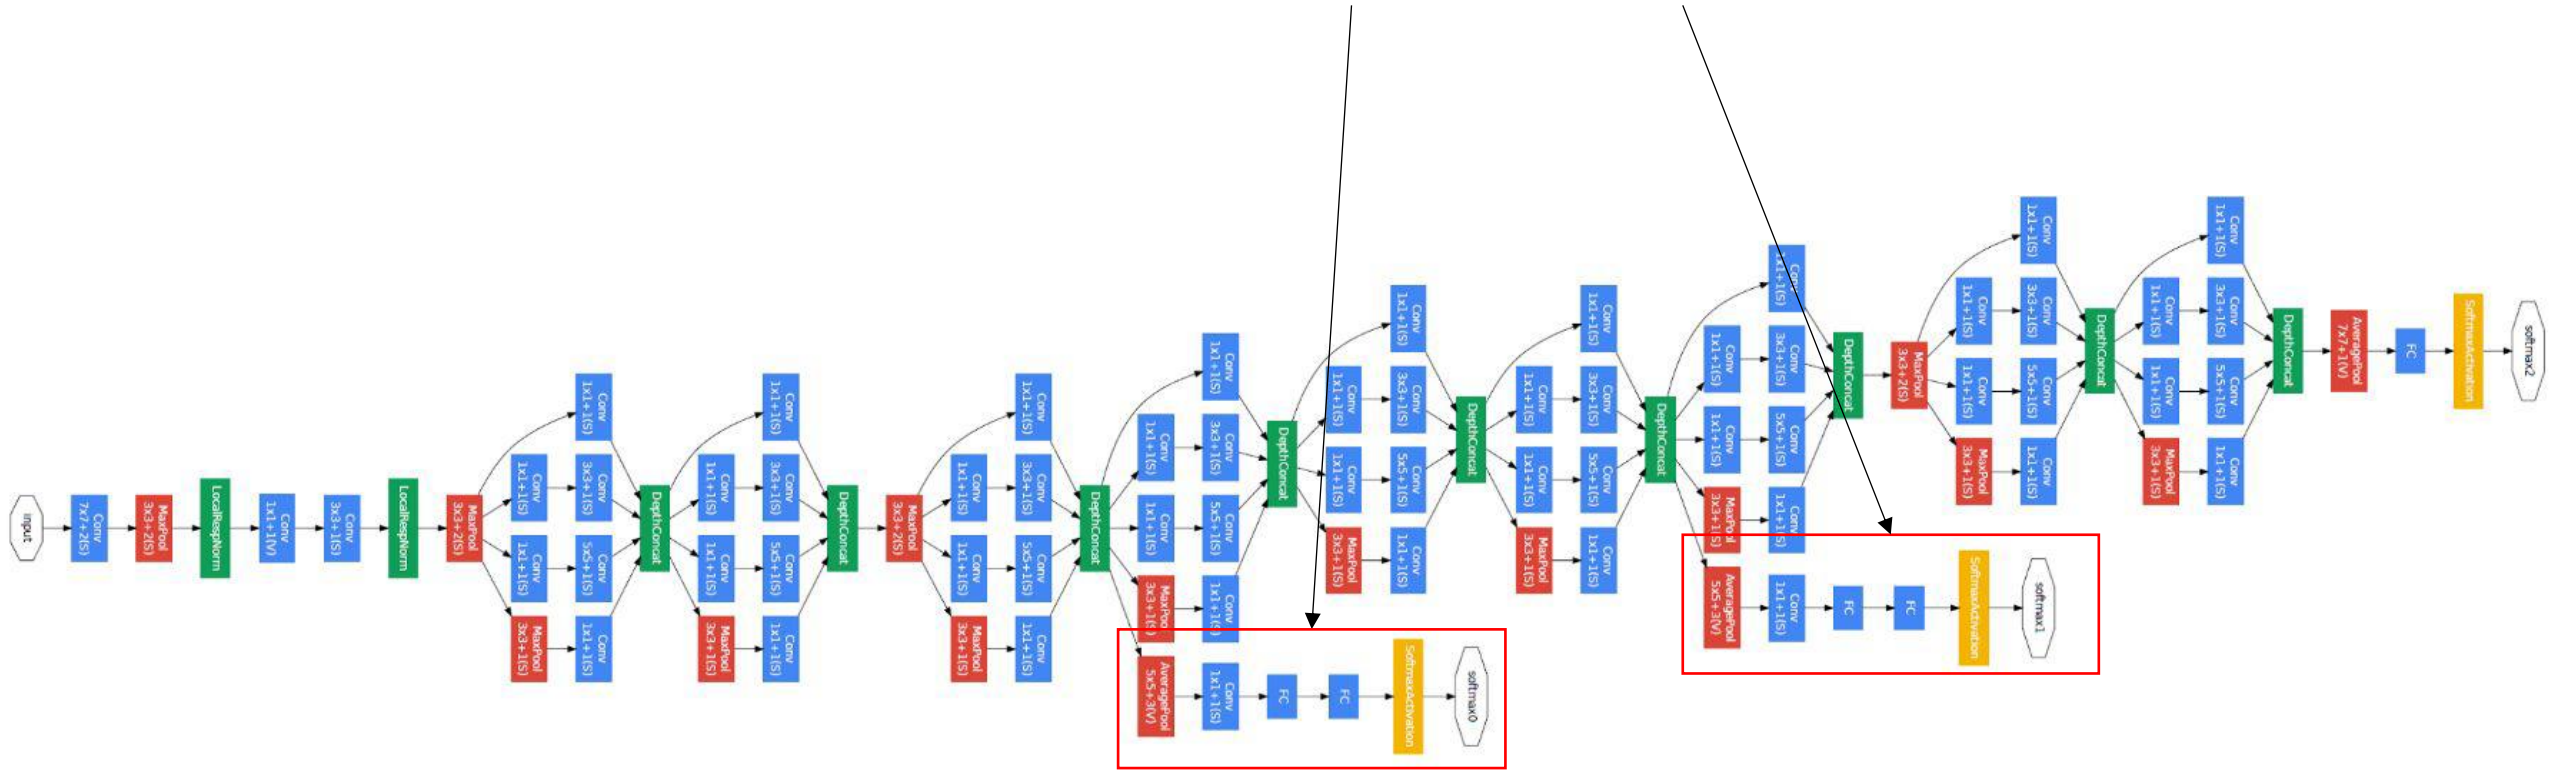
(a) Inception module, naïve version

GoogleNet (Inception)



GoogleNet (Inception)

Дополнительные классификаторы для борьбы с затуханием градиентов



Transfer Learning

Transfer Learning

Часто датасет под какую-либо задачу для обучения сети содержит мало объектов.
И если обучать сеть на этом датасете с нуля, сеть переобучится.

Пример: медицинские датасеты изображений опухолей, машинный перевод с малораспространенных языков (татарский), etc

Transfer Learning

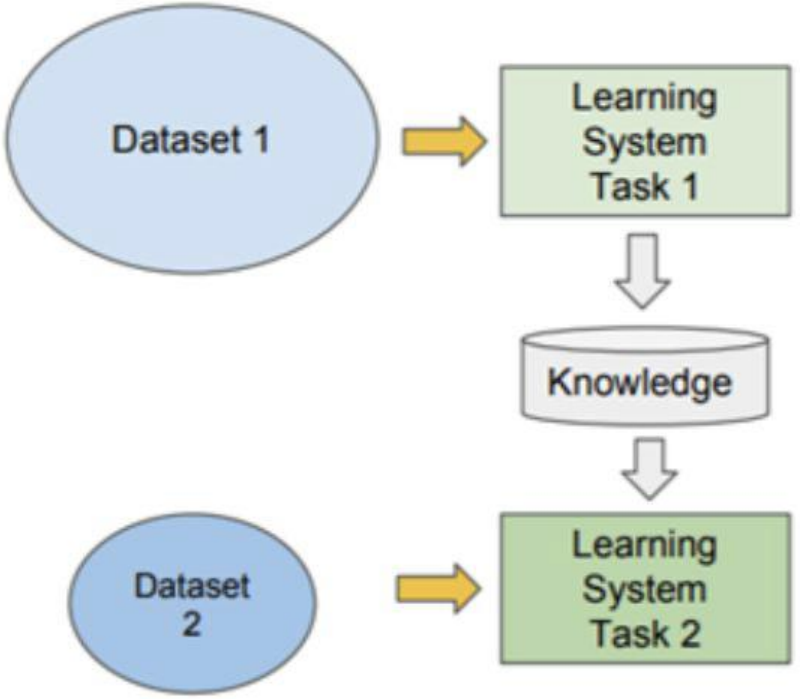
Часто датасет под какую-либо задачу для обучения сети содержит мало объектов.

И если обучать сеть на этом датасете с нуля, сеть переобучится.

Пример: медицинские датасеты изображений опухолей, машинный перевод с малораспространенных языков (татарский), etc

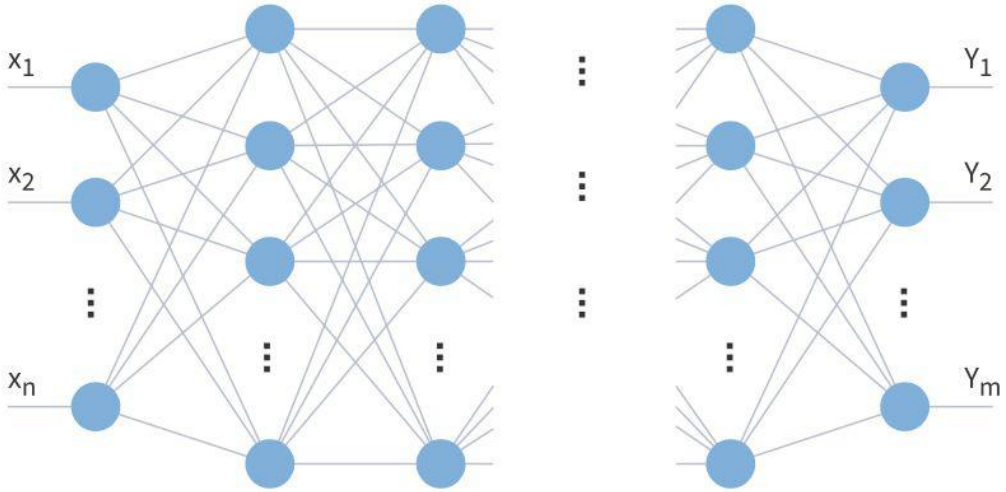
Идея:

использовать знания, полученные другими сетями на похожих задачах.



Дообучение сети (Fine-tuning)

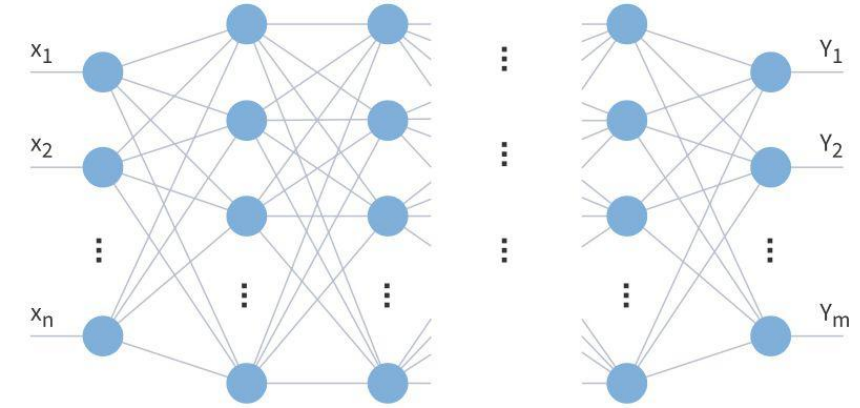




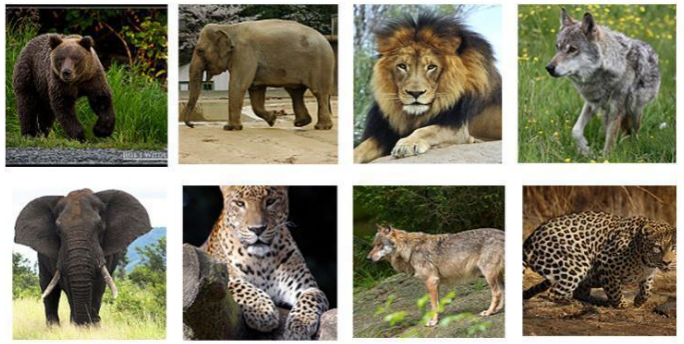
Дообучение сети (Fine-tuning)

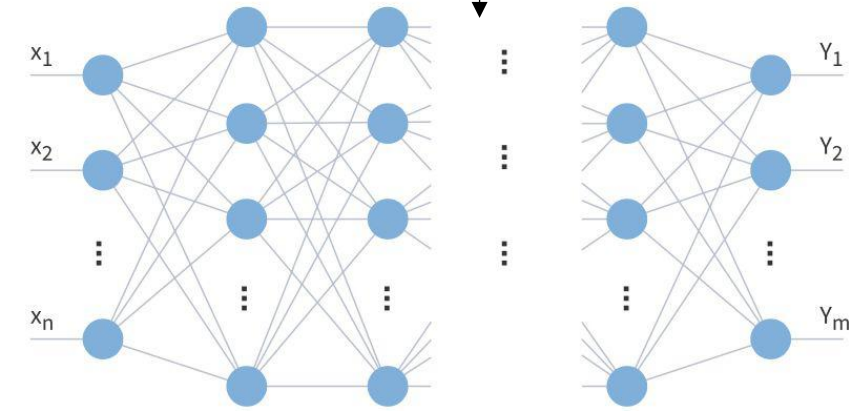
1.





2.

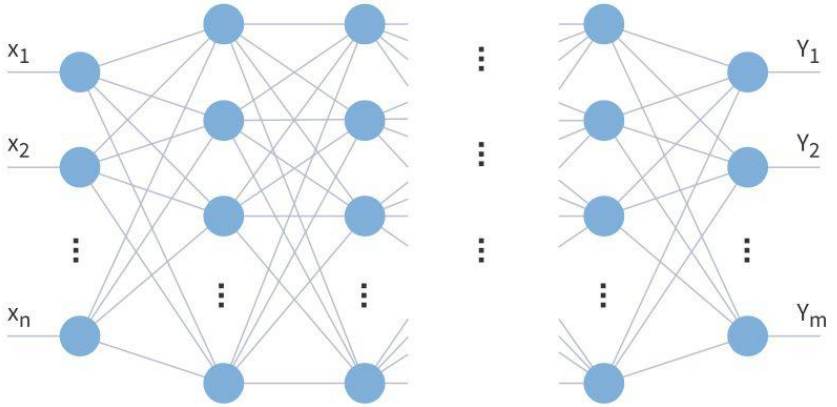




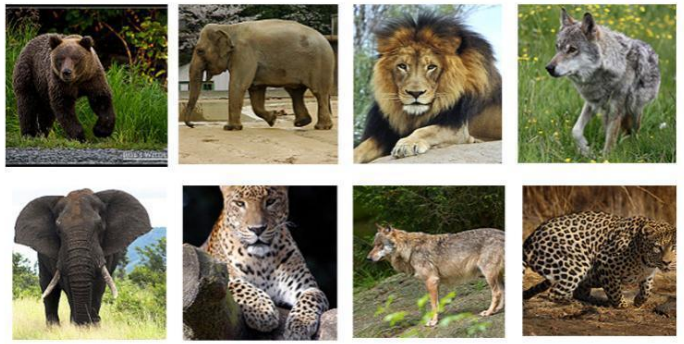
Дообучение сети (Fine-tuning)

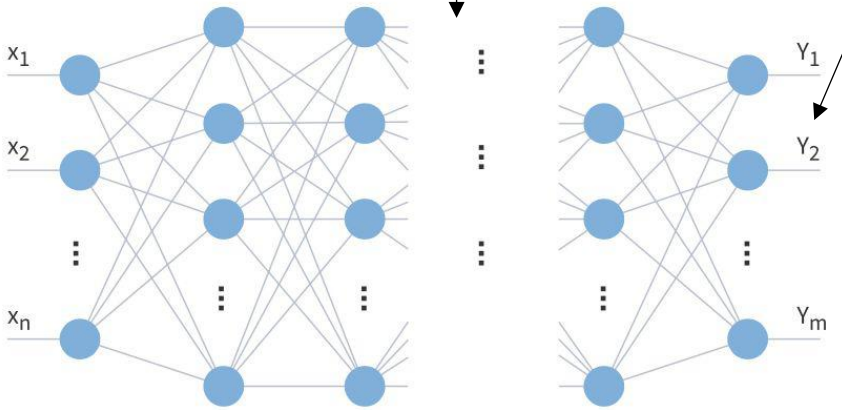
1.





2.



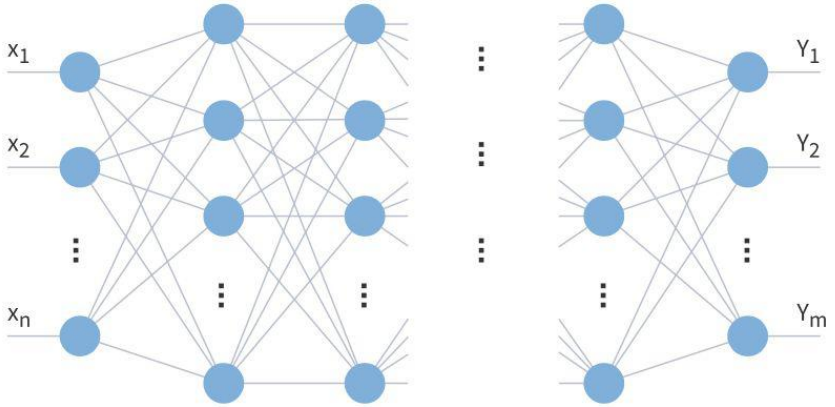


Здесь должно быть
10 нейронов!

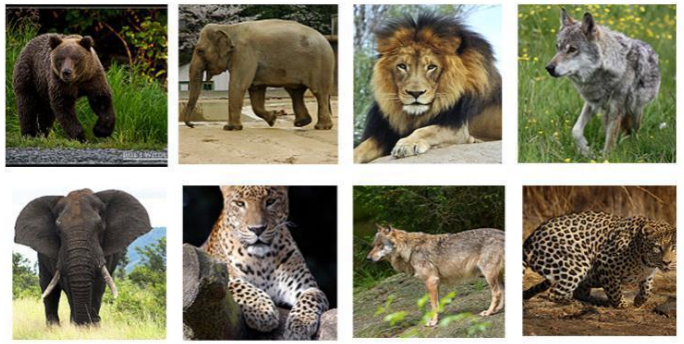
Дообучение сети (Fine-tuning)

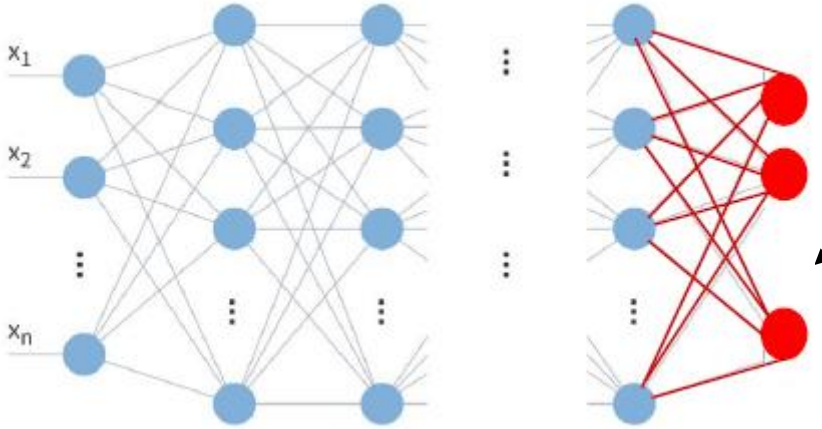
1.





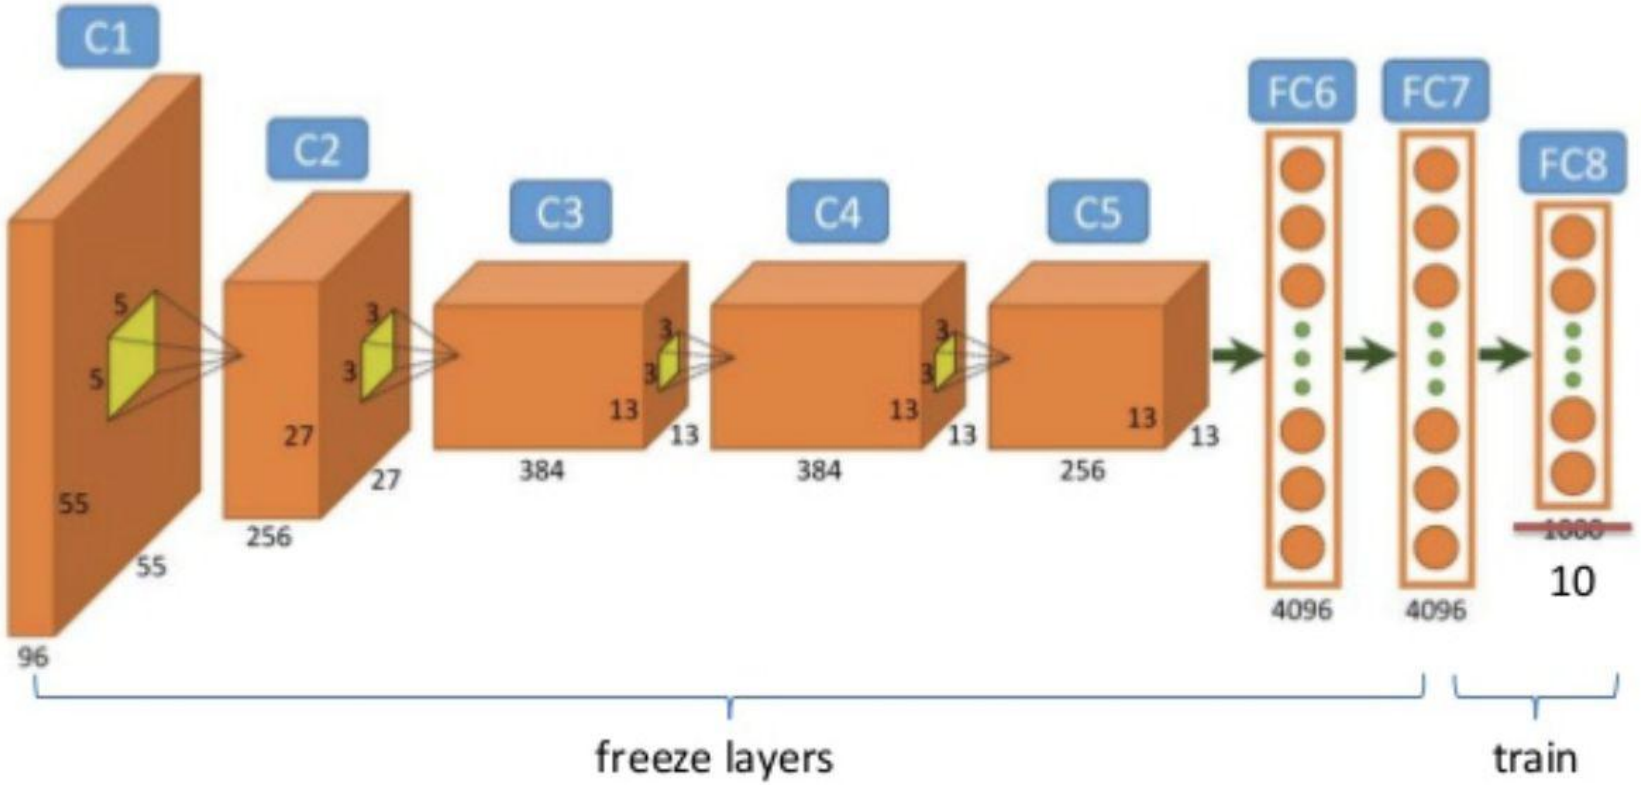
2.





Выкидываем последний слой и заменяем на новый из 10 нейронов

Fine-tuning Pretrained Network

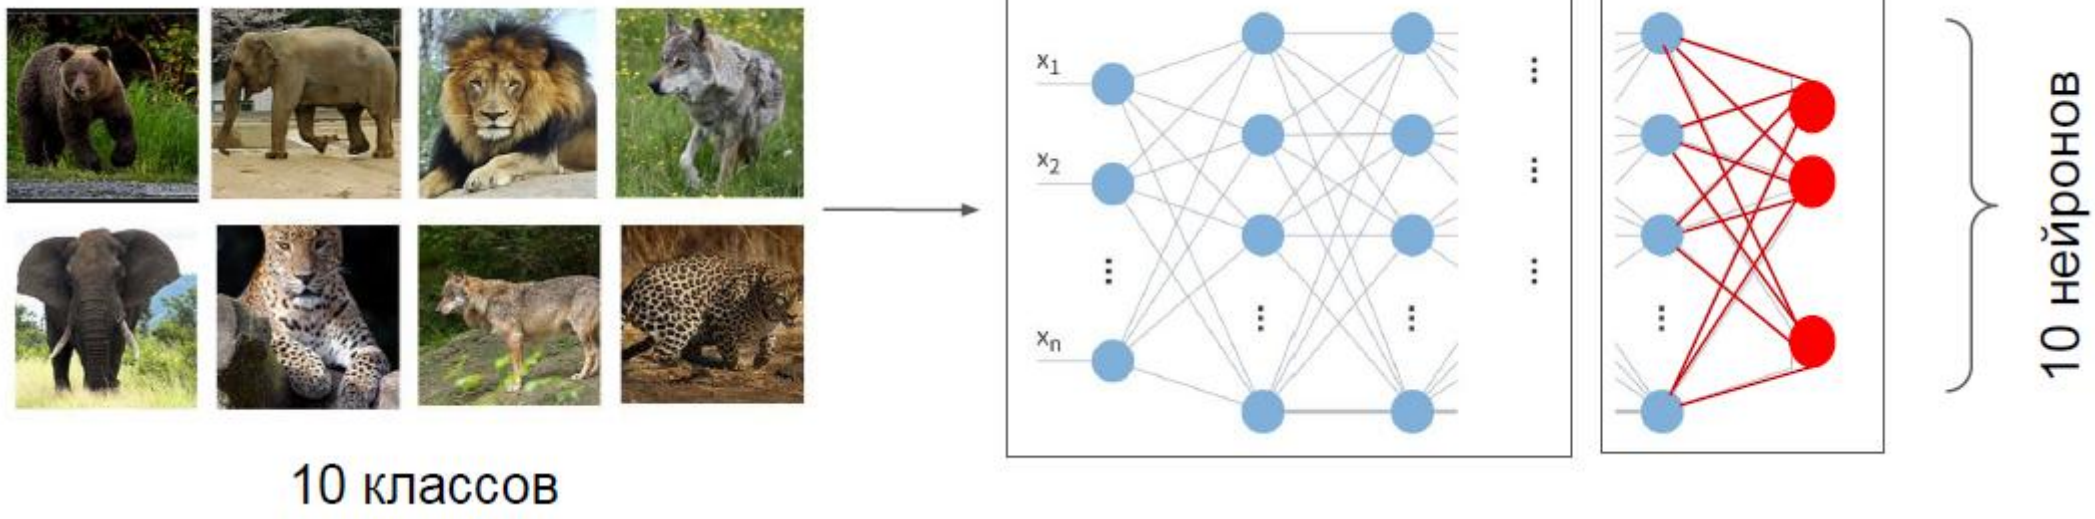


Заморозка слоев

Заморозим первые слои:

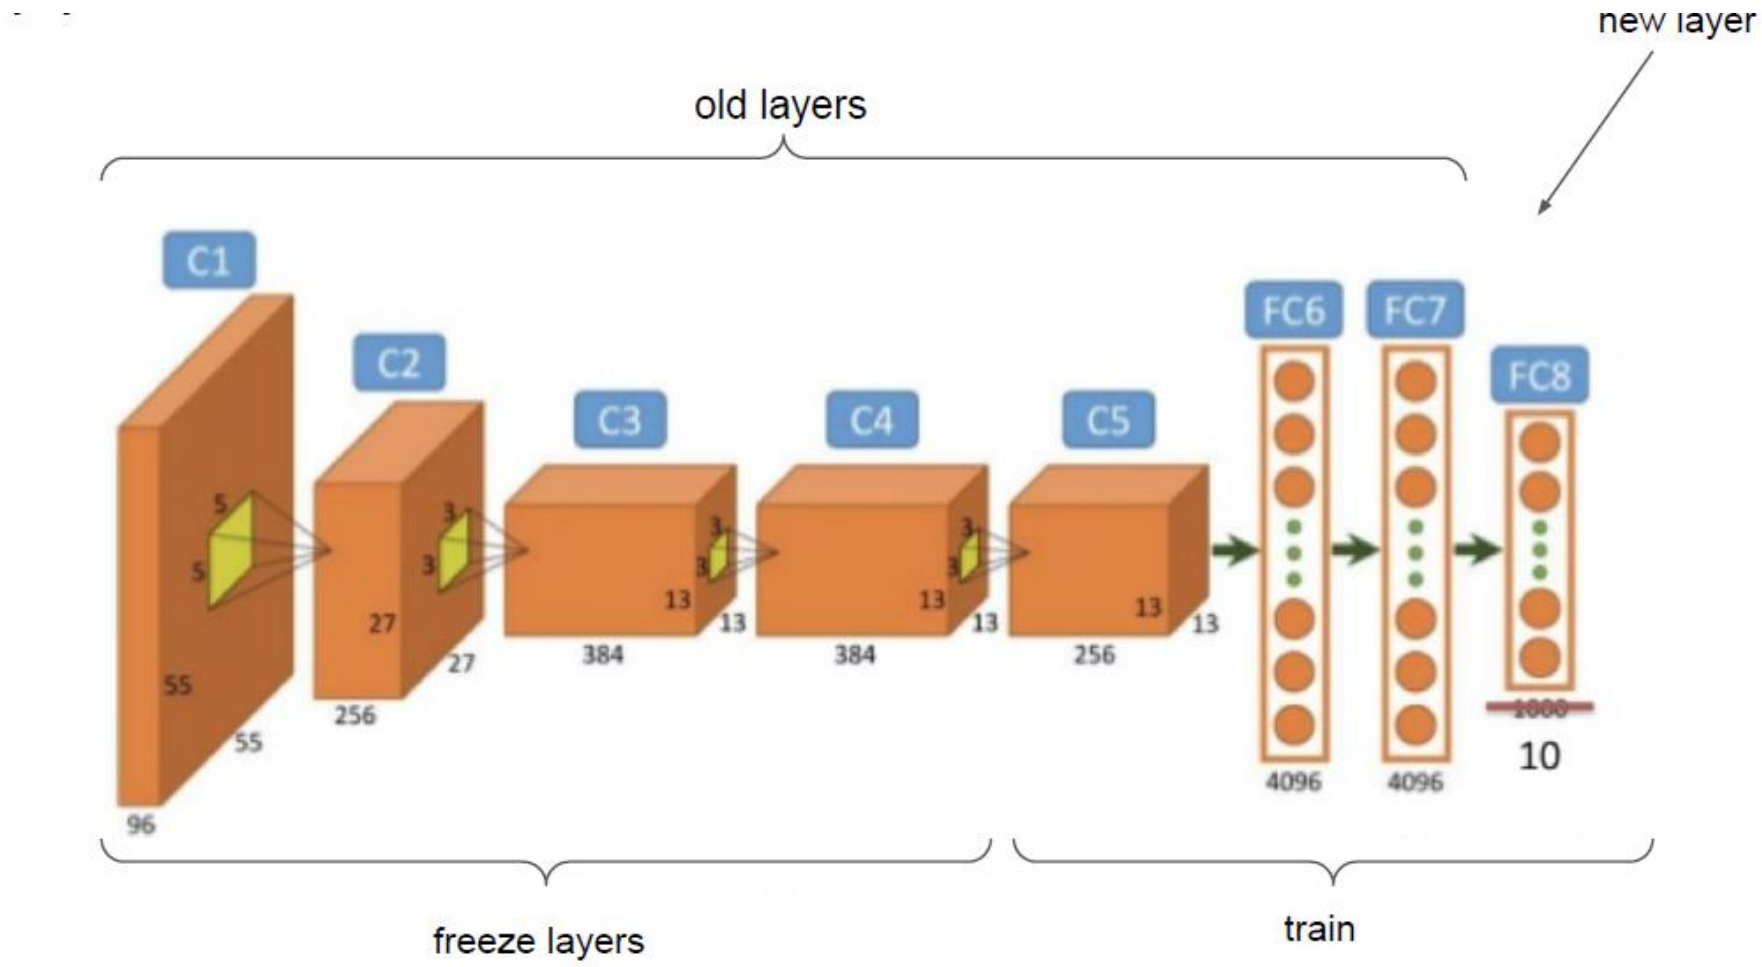
их веса не будут обновляться

Эти веса обновляться будут



Мы можем выбирать, какие слои замораживать и какие слои заменять

Можно заморозить 10 первых слоев, тренировать 5 оставшихся, среди которых 2 будут новых слоя.



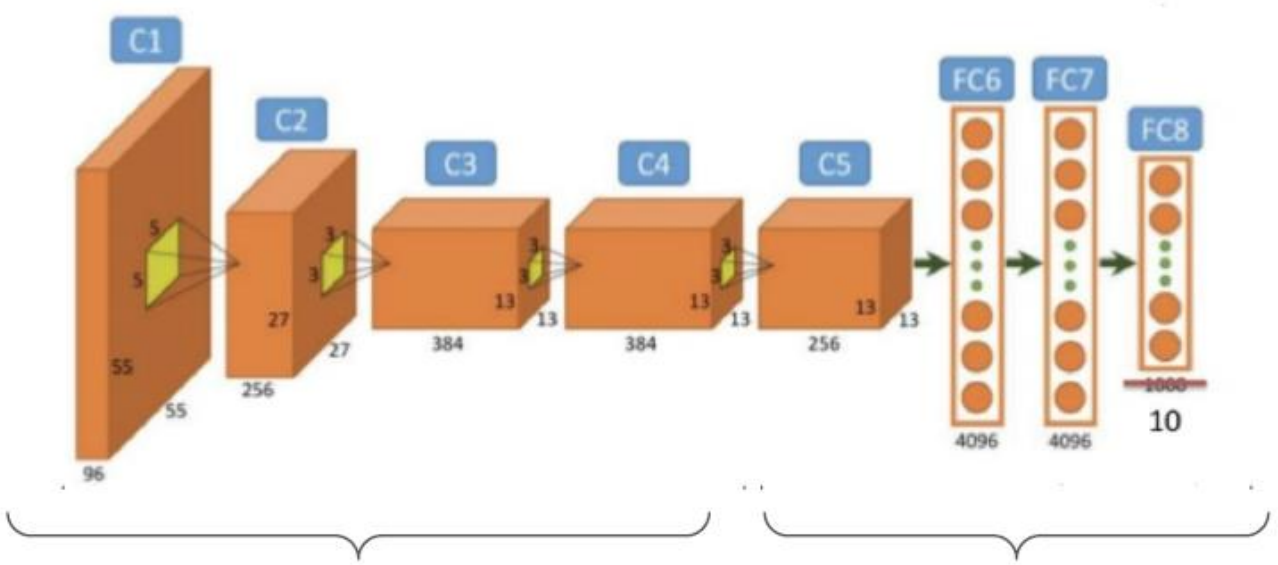
Fine-tuning

- Замораживаются верхние (первые) слои сети, нижние дообучаются. Верхние слои выделяют низкоуровневую информацию, и они научились хорошо это делать при предобучении. Нижние слои выделяют из информации, полученной из верхних слоев, специфическую для задачи информацию, поэтому их нужно дообучать.

- Сколько слоев замораживать, зависит от различия между датасетами, сложности задачи и объема датасета для дообучения.

Fine-tuning

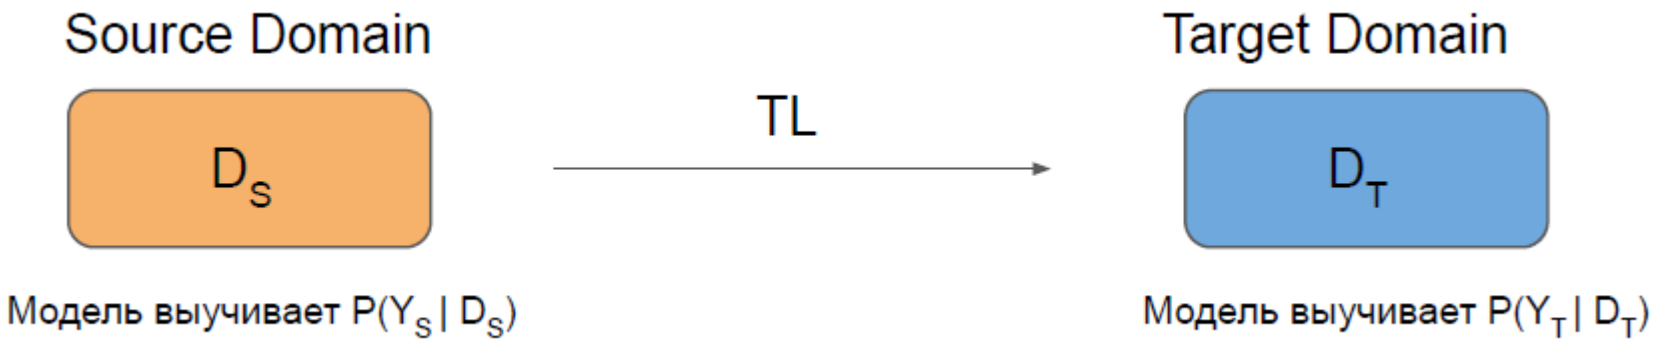
Чем больше в target задаче тренировочных данных и чем сильнее source и target задачи отличаются между собой, тем больше слоев нужно дообучать.



Верхние слои содержат более общую инфрмацию, которая пригодится при дообучении на новой задаче

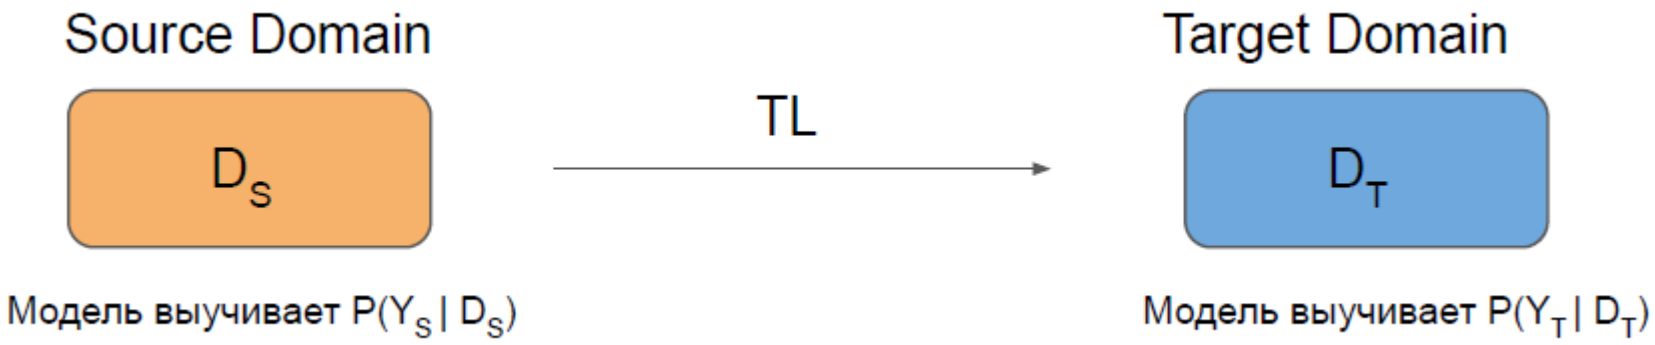
Нижние слои содержат специфическую для задачи информацию. При переходе на новую задачу нужно научить сеть выделять другую инфу, нужную для решения новой задачи

Transfer Learning



Понятия Transfer Learning, Domain Adaptation и Multi-task Learning часто используются в одном контексте

Transfer Learning



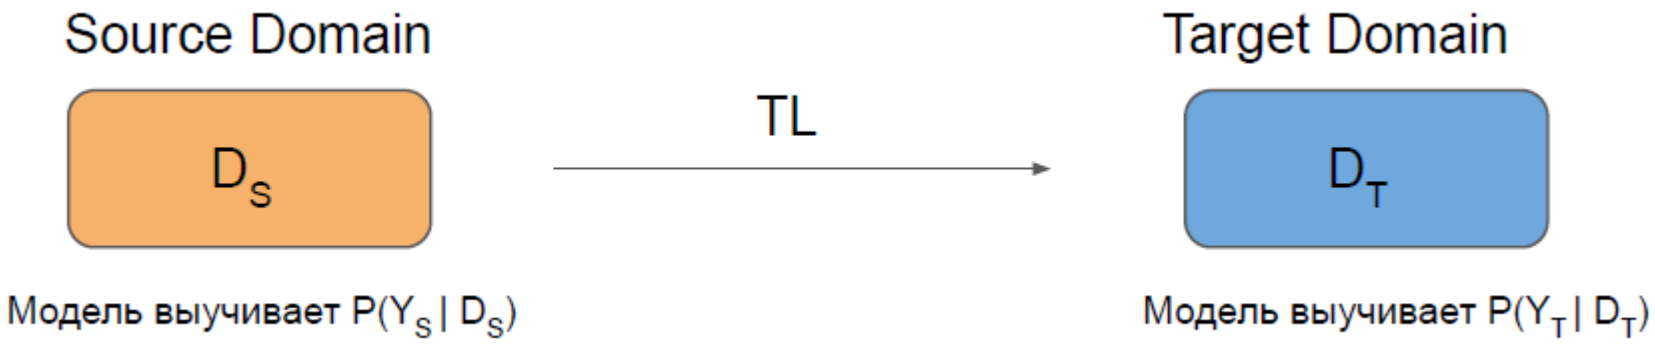
1. $D_S \neq D_T$

Пространства признаков двух доменов — разные.

Пример:

В NLP два датасета текстов на двух разных языках.

Transfer Learning



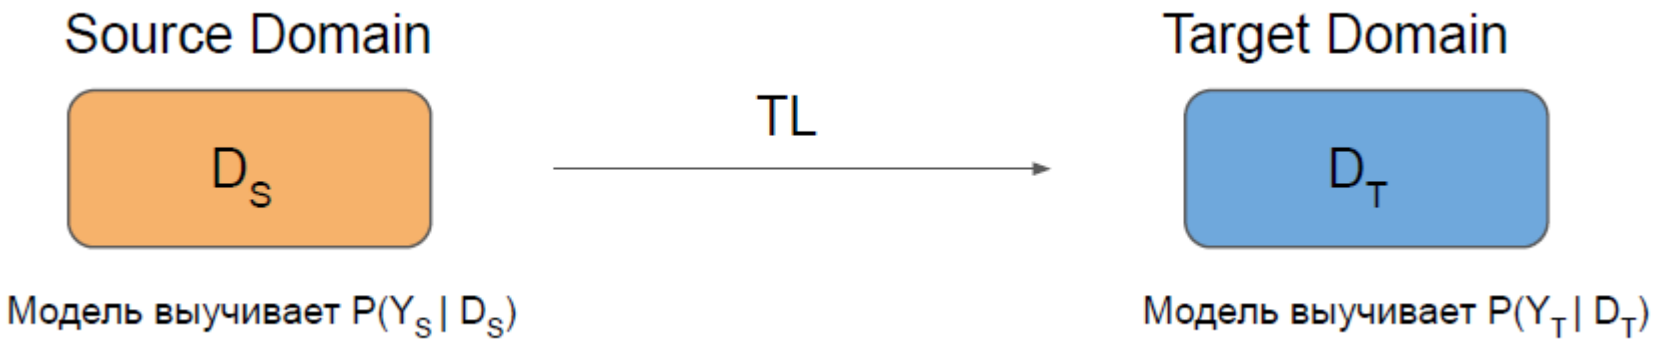
2. $P(D_S) \neq P(D_T)$

Распределения признаков в двух доменах разные. Такой TL называется Domain Adaptation.

Пример:

Датасет ревью на фильмы на Кинопоиске и датасет ревью на мобильные приложения в Google Play. И там, и там задача — предсказать оценку ревью (от 0 до 5)

Transfer Learning



3. $Y_S \neq Y_T$: $P(Y_S|D_S) \neq P(Y_T|D_T)$

Распределения признаков в двух доменах разные. Такой TL называется Domain Adaptation.

Пример:

Датасет лиц людей.

Задача 1: классификация лиц по половому признаку,

Задача 2: классификация лиц по расовому признаку

Transfer Learning

Разные домены: задача одна и та же: классификация изображений цифр на 10 классов

Домены (распределения D_S и D_T) — разные

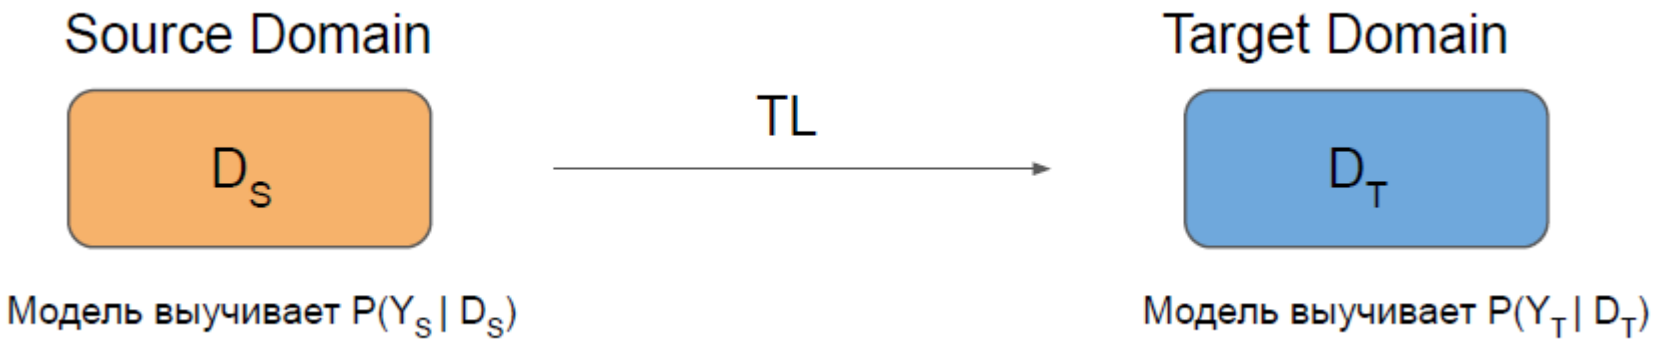


MNIST



SVHN

Transfer Learning



4. Supervised / Unsupervised

Есть ли лейблы у D_T

Пример:

Датасет лиц людей.

D_S : размеченные лица по id

D_T : неразмеченные лица людей из другой части мира

Transfer Learning Ideas

Когда нейронная сеть обучается, она учится выделять из объектов inter-domain и intra-domain информацию

inter-domain: расположение элементов на лице, выражения лиц

intra-domain: цвет лица, широта глаз



Transfer Learning Ideas

Когда нейронная сеть обучается, она учится выделять из объектов inter-domain и intra-domain информацию

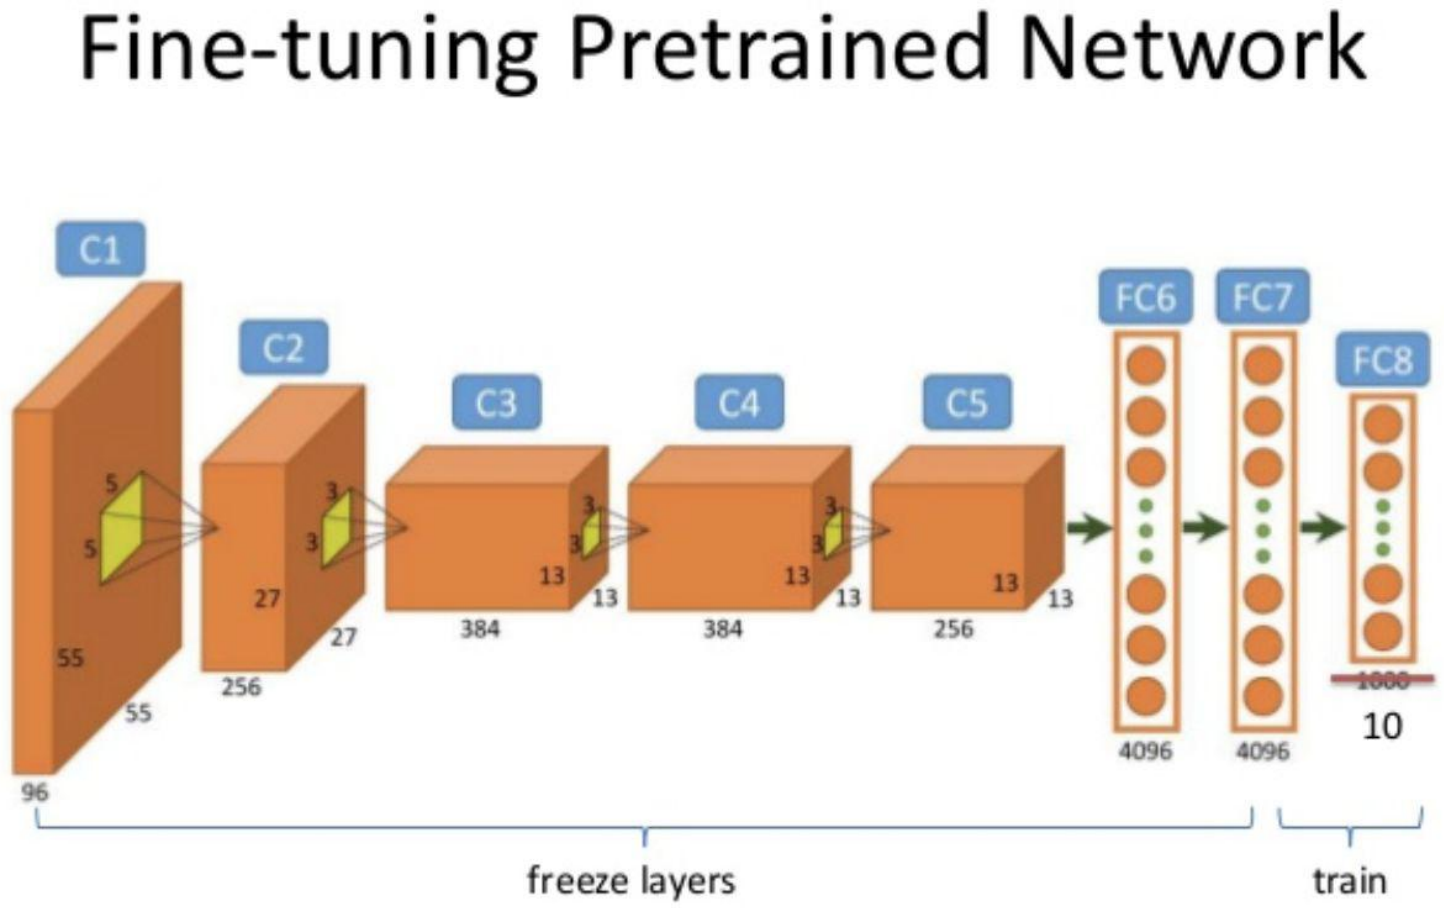
inter-domain: расположение элементов на лице, выражения лиц

intra-domain: цвет лица, широта глаз

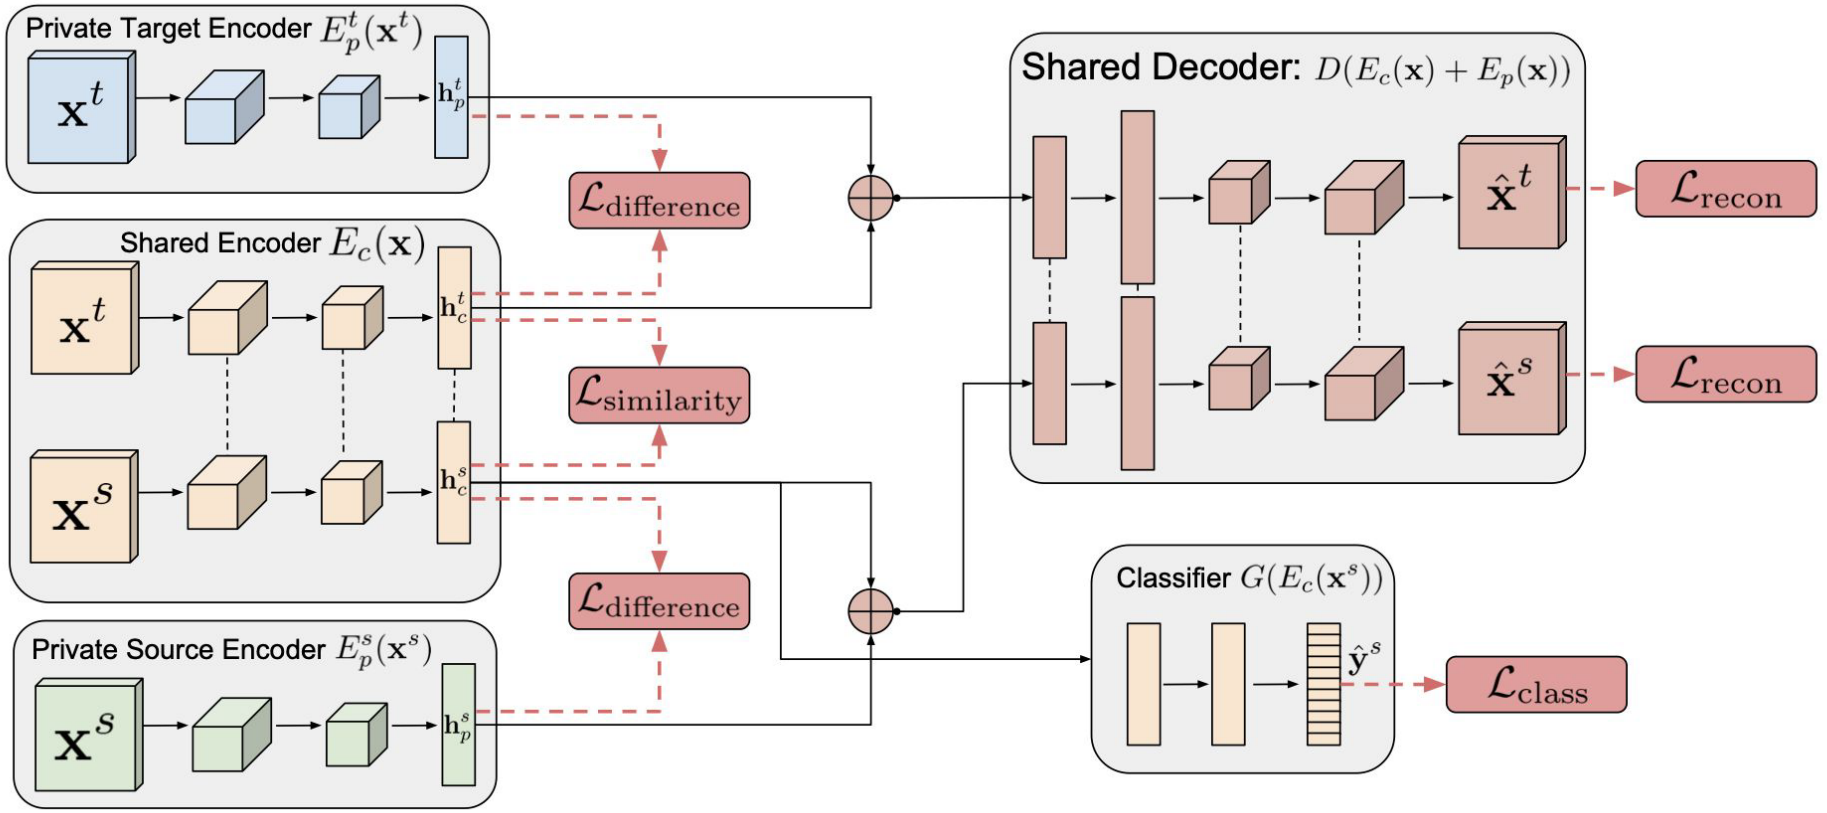


Как перенести только нужные знания сети (inter-domain) на новый домен?

Idea 1 : Fine-tuning



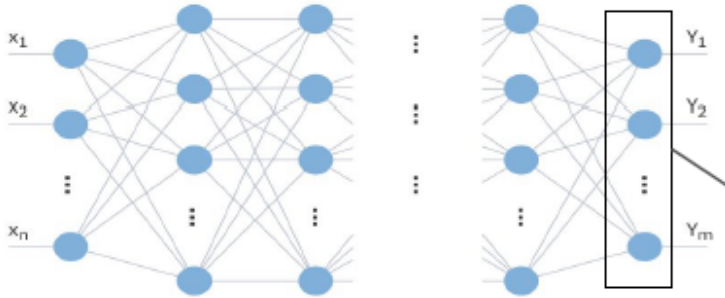
Idea 2: Learn a little more



Transfer Learning: «extreme cases»



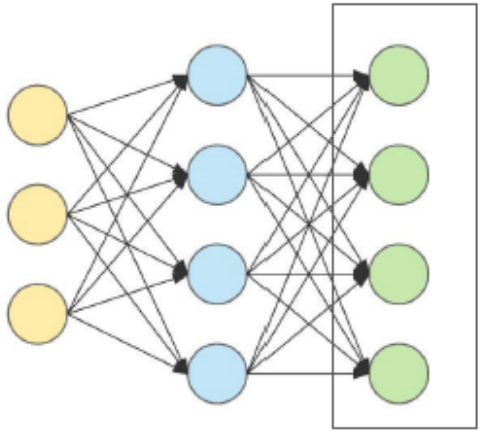
Сеть ResNet, (пред)обученная на ImageNet



Сеть-teacher

нет доступа к ее коду, мы можем только получать эмбеддинги

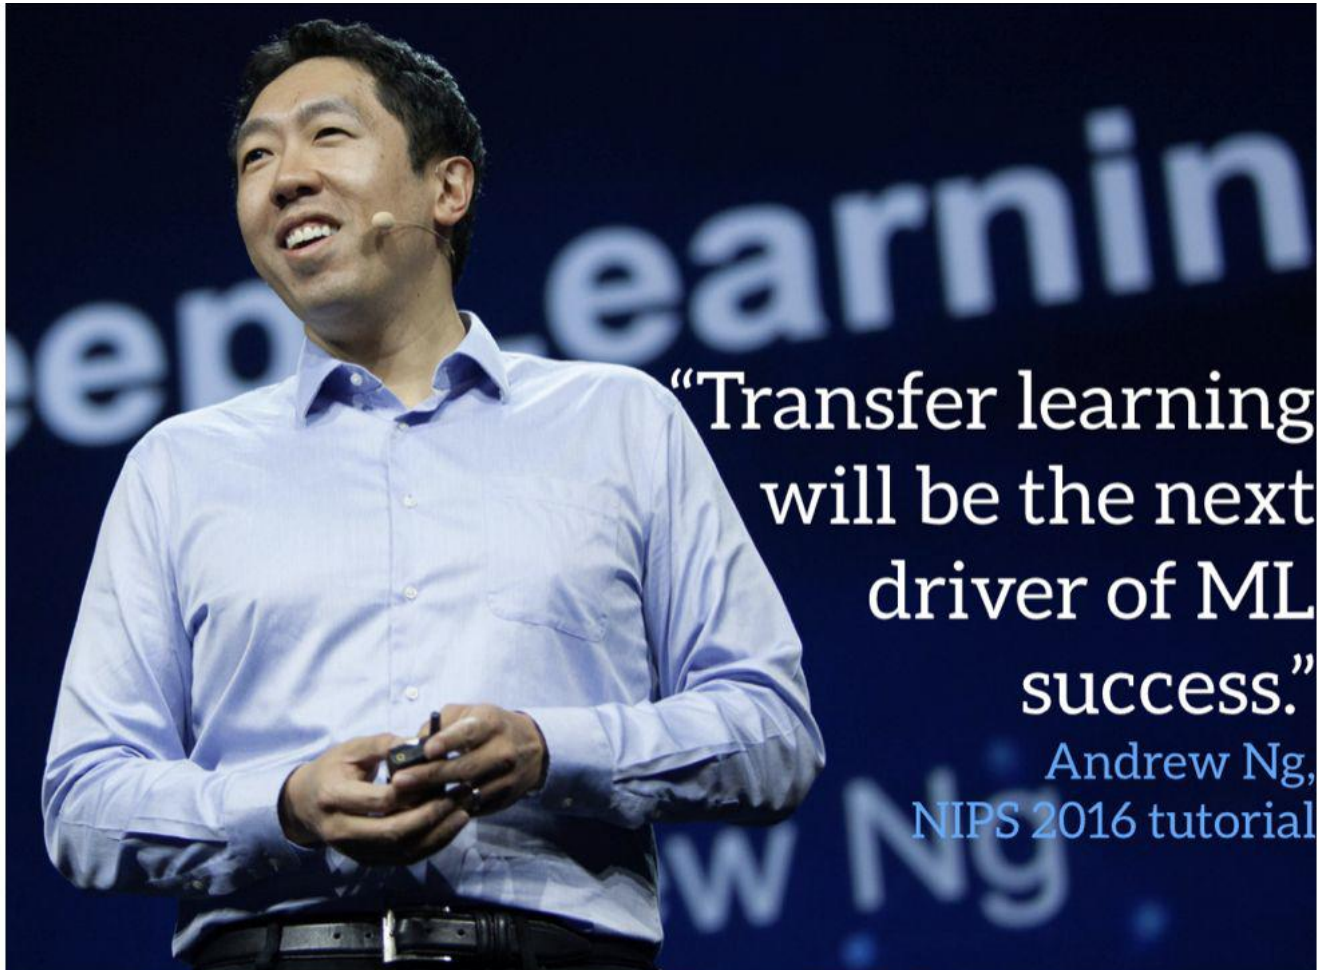




Loss (e.g MSE), который заставляет оба эмбеддинга быть похожими

Сеть-student

Transfer Learning is a new black



Transfer Learning is a new black

